

(基础知识回顾)主要是数的基础,根统(多元)内容。——统计方法部分

1. 向量和矩阵微分

$$x \in \mathbb{R}^n \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

$$f(x): \mathbb{R}^n \rightarrow \mathbb{R} \quad \frac{\partial f}{\partial x} = \nabla_x f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}$$

$$A \in \mathbb{R}^{m \times n} \quad f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R} \quad A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \quad \frac{\partial f}{\partial A} = \begin{bmatrix} \frac{\partial f}{\partial a_{11}} & \cdots & \frac{\partial f}{\partial a_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f}{\partial a_{m1}} & \cdots & \frac{\partial f}{\partial a_{mn}} \end{bmatrix}$$

$$\frac{\partial (C_1 f(x) + C_2 g(x))}{\partial x} = C_1 \frac{\partial f}{\partial x} + C_2 \frac{\partial g}{\partial x} \quad \frac{\partial (f(x) \cdot g(x))}{\partial x} = \frac{\partial f}{\partial x} \cdot g + \frac{\partial g}{\partial x} \cdot f$$

$$\frac{\partial f}{\partial x} = \left(\frac{\partial f}{\partial x_i} \right)^T$$

$$dx = \begin{bmatrix} dx_1 \\ \vdots \\ dx_n \end{bmatrix}$$

f 是标量的话 $f = \text{Tr}f$
 $df = d(\text{Tr}f) = \text{Tr}(df)$

$$d(AB) = (dA)B + A(dB) \quad d(A+B) = dA + dB \quad d(A^T) = (dA)^T$$

A 可以不是标量,而是向量/矩阵,微分和迹运算也可交换 $d(\text{Tr}(A)) = \text{Tr}(dA)$
 迹的性质: $\text{Tr}(A+B) = \text{Tr}(A) + \text{Tr}(B)$ $\text{Tr}(AB) = \text{Tr}(BA)$ $\text{Tr}(A) = \text{Tr}(A^T)$

$$\text{Tr}(A_1 A_2 \cdots A_n) = \text{Tr}(A_n A_1 \cdots A_{n-1}) = \text{Tr}(A_{n-1} A_n A_1 \cdots A_{n-2})$$

这个要满足矩阵乘法性质

$$\text{Tr}(A^T B) = \sum_j \sum_i A_{ij} B_{ij}$$

$$df(x_1 \cdots x_n) = \frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 + \cdots + \frac{\partial f}{\partial x_n} dx_n \in \text{多元函数}$$

迹微分法 $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ $A \in \mathbb{R}^{m \times n}$ 无关量抛开!

$$df = \text{Tr}\left(\left(\frac{\partial f}{\partial A}\right)^T dA\right)$$

$$\text{做一个练习, } f(x) = x^T A x \xrightarrow{x \in \mathbb{R}^n \quad A \in \mathbb{R}^{n \times n}} \frac{\partial f}{\partial x} = ? \quad \frac{\partial f}{\partial x} = ?$$

$$df = d\text{Tr}(f) = \text{Tr}(df) = \text{Tr}(dx^T \cdot A x + x^T (dA \cdot x + A dx))$$

$$= \text{Tr}(dx^T \cdot A x) + \text{Tr}(x^T A dx)$$

$$= \text{Tr}(x^T A^T dx + x^T A dx) = \text{Tr}((x^T A^T + x^T A) dx)$$

$$\text{故 } \frac{\partial f}{\partial x} = (x^T A^T + x^T A)^T = A x + A^T x$$

$$df = \text{Tr}(x^T dA \cdot x)$$

$$= \text{Tr}(x x^T dA)$$

$$\frac{\partial f}{\partial A} = (x x^T)^T = x x^T$$

$$\text{范数 } \|A\|_F^2 = \text{Tr}(A^T A)$$

$$\text{行列式 } \frac{\partial |A|}{\partial A} = (A^*)^T \quad A^* \text{为 } A \text{ 的伴随阵}$$

$$A^* \cdot A = A \cdot A^* = |A| \cdot I$$

$$\text{若 } A \text{ 可逆, } A = |A| \cdot A^{-1}$$

$$x \text{ 可逆 } dx^{-1} = ? \quad x \cdot x^{-1} = I$$

$$(dx) \cdot x^{-1} + x \cdot d(x^{-1}) = 0$$

$$dx^{-1} = -x^{-1}(dx)(x^{-1})$$

若不是实值函数,

$$f: \mathbb{R}^m \rightarrow \mathbb{R}^n \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_m \end{bmatrix}$$

$$f(x) = \begin{bmatrix} f_1(x) \\ \vdots \\ f_n(x) \end{bmatrix}$$

转化为一堆实值函数

$$\frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1(x)}{\partial x_1} & \cdots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_n(x)}{\partial x_1} & \cdots & \frac{\partial f_n(x)}{\partial x_n} \end{bmatrix} \quad \begin{matrix} \downarrow \\ \text{该方向为 } f \\ \xrightarrow{\quad} \text{该方向} \\ \text{为 } x \end{matrix}$$

2. 概率论中那些进阶点的知识 (当然也有基础的)

$$(X, Y) = n \text{ 维随机变量} \quad \text{cov}(X, Y) = E((X - EX)(Y - EY)) \quad \begin{matrix} \text{cov}(x, x) \\ = \text{Var}(x) \end{matrix}$$

$$\text{cov}(X, Y) = E(XY) - E(X) \cdot E(Y)$$

$$\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{cov}(X, Y) \quad \begin{matrix} \text{若 } X, Y \text{ 独立} \\ \text{则 } \text{cov}(X, Y) = 0 \end{matrix}$$

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{Var}(X) \cdot \text{Var}(Y)}}$$

若 $\text{cov}(X, Y) = 0$
则 X, Y 不一定独立
但一定不相关

$$\text{设 } X \text{ 是 } n \text{ 维随机变量} \quad X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad EX = \begin{bmatrix} EX_1 \\ \vdots \\ EX_n \end{bmatrix}$$

$$\text{cov}(X) = E((X - EX)(X - EX)^T) = \begin{bmatrix} \text{Var}(X_1) & \text{cov}(X_1, X_2) & \cdots & \text{cov}(X_1, X_n) \\ \text{cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_n, X_1) & \text{cov}(X_n, X_2) & \cdots & \text{Var}(X_n) \end{bmatrix}$$

这个矩阵是 X 的
方差-协方差矩阵

性质: 非负定, 对称

$$n \text{ 维随机变量 } X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad \text{联合密度函数 } p(x_1, x_2, \dots, x_n)$$

$$\begin{bmatrix} y_1 = g_1(x_1, x_2, \dots, x_n) \\ \vdots \\ y_n = g_n(x_1, x_2, \dots, x_n) \end{bmatrix} \quad \text{有连续偏导且} \quad \begin{bmatrix} x_1 = h_1(y_1, \dots, y_n) \\ \vdots \\ x_n = h_n(y_1, \dots, y_n) \end{bmatrix} \quad \begin{matrix} \text{唯一} \\ \text{(逆唯一)} \end{matrix}$$

$$J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \cdots & \frac{\partial x_n}{\partial y_n} \end{vmatrix} \quad \begin{matrix} P_Y(y_1, y_2, \dots, y_n) \\ = P_X(h_1, h_2, \dots, h_n) \\ \cdot |J| \end{matrix}$$

若 $X \sim N_n(\vec{\mu}, \Sigma)$ 对于任意常数矩阵 $A_{m \times n}$, 有 $Y = AX \sim N_m(AM, A\Sigma A^T)$

$$m \text{ 维常向量} \quad y = Ax + b \sim N_m(AM + b, A\Sigma A^T)$$

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \quad M = \begin{bmatrix} M_1 \\ \vdots \\ M_n \end{bmatrix} = \begin{bmatrix} E(X_1) \\ \vdots \\ E(X_n) \end{bmatrix} \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \cdots & \Sigma_{1n} \\ \vdots & \ddots & \vdots \\ \Sigma_{n1} & \cdots & \Sigma_{nn} \end{bmatrix} \quad \text{每个分量} \quad X_i \sim N(M_i, \Sigma_{ii})$$

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \quad A \in \mathbb{R}^{m \times n}, \quad B \in \mathbb{R}^{k \times n}, \quad m \text{ 维向量 } c.$$

$$E(Ax+c) = AE(x)+c, \quad \text{Var}(Ax+c) = A \text{Var}(x) \cdot A^T$$

$$\text{Cov}(Ax, By) = A \text{Cov}(x, y) B^T$$

$$\text{Cov}(x, x) = \text{Var}(x) \quad \text{方差-协方差矩阵.}$$

3. 相关基础知识(尤其关于数理统计)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

$$x \sim N(\mu, \sigma^2)$$

$$\frac{x-\mu}{\sigma} \sim N(0, 1)$$

$$\bar{x} \sim N(\mu, \frac{\sigma^2}{n})$$

① 卡方分布 $x_1, x_2, \dots, x_n \sim N(0, 1)$ 假设来自 $N(0, 1)$ 且独立同分布 $\chi^2 = x_1^2 + x_2^2 + \dots + x_n^2 \sim \chi^2(n) \rightarrow E(\chi^2) = n, \text{Var}(\chi^2) = 2n,$

$$\chi^2(n) = G(a(\frac{n}{2}, \frac{1}{2})) \quad \chi^2(1) = G(a(\frac{1}{2}, \frac{1}{2}))$$

② F 分布. $x_1 \sim \chi^2(m) \quad x_2 \sim \chi^2(n) \quad x_1, x_2 \text{ 独立.} \quad F = \frac{\frac{x_1}{m}}{\frac{x_2}{n}} \sim F(m, n)$

$$F_{\alpha}(m, n) = \frac{1}{F_{1-\alpha}(n, m)}.$$

③ t 分布. $x_1, x_2 \text{ 独立} \quad x_1 \sim N(0, 1) \quad x_2 \sim \chi^2(n) \quad t = \frac{\bar{x}_1}{\sqrt{\frac{x_2}{n}}} \sim t(n)$

正态分布下的样本. x_1, x_2, \dots, x_n from $N(\mu, \sigma^2)$

样本均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2. \quad \bar{x} \sim N(\mu, \frac{\sigma^2}{n})$

$$\frac{(n-1)s^2}{\sigma^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sigma^2} \sim \chi^2(n-1) \quad t = \frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t(n-1)$$

引入 设 x_1, x_2, \dots, x_m 来自 $N(\mu_1, \sigma_1^2)$ y_1, y_2, \dots, y_n from $N(\mu_2, \sigma_2^2)$

两样本相互独立. $\frac{s_x^2}{s_1^2} \sim \chi^2(m-1) \quad \frac{(m-1)s_x^2}{s_1^2} \sim \chi^2(m-1) \quad \frac{(m-1)s_x^2}{s_2^2} \sim \chi^2(n-1)$

$$F = \frac{\frac{s_x^2}{s_1^2}}{\frac{s_y^2}{s_2^2}} \sim F(m-1, n-1) \quad \text{若 } \sigma_1^2 = \sigma_2^2 = \sigma^2 \text{ 则.}$$

$$s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2} \quad \text{然后可得} \quad \frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(n+m-2)$$

“假设检验”这里你只要这样想：假设条件是成立的，然后在此基础上看偏的程度大小。

$$\text{rank}(x) \geq \text{rank}(x^T x)$$

$$H = X(x^T x)^{-1} x^T \text{ 的性质:}$$

$$H \text{ 是 } n \text{ 阶对称阵} \quad H = H^T.$$

$$\text{Tr}(H) = p+1 \rightarrow \text{Tr}(H) = \text{Tr}(X(x^T x)^{-1} x^T) = \text{Tr}((x^T x)^{-1} x^T x) = \text{Tr}(I_{p+1})$$

若 $X \sim N_n(M, \frac{1}{2}I_n)$ 若 C 是一个对称矩阵且 $\text{rank}(C) = r$, $C^2 = C$ ($r \leq n$)

$$\text{那么 } \frac{X^T C X}{\frac{1}{2}} \sim \chi^2(r, f_2) \quad f_2 = \frac{1}{2} M^T C M.$$

A 为 n 阶对称阵

B 为 $m \times n$ 阵

$$BA = 0_{m \times n}$$

$\Leftrightarrow BX$ 和 $X^T A X$ 相独立.

A, B 为 n 阶对称矩阵 $\Leftrightarrow X^T A X$ 与 $X^T B X$ 相独立.

$$AB = 0_{n \times n}$$

$X \sim N_n(M, \Sigma)$ 给定 $m \times n$ 常矩阵 A 和 m 维向量 b .

$$y = Ax + b \sim N_m(AM + b, A\Sigma A^T)$$

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1P} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2P} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{P1} & \sigma_{P2} & \cdots & \sigma_{PP} \end{bmatrix} \quad \begin{array}{l} \text{其中每个分量 } x_j \\ x_j \sim N(M_j, \sigma_{jj}) \\ \text{也满足正态分布} \end{array}$$

$$M = \begin{bmatrix} M_1 \\ \vdots \\ M_P \end{bmatrix} \quad n \text{ 阶方阵 } A. \quad A^* = \begin{bmatrix} A_{11} & \cdots & A_{1n} \\ A_{21} & \cdots & A_{2n} \\ \vdots & \ddots & \vdots \\ A_{n1} & \cdots & A_{nn} \end{bmatrix} \quad A^{-1} = \frac{A^*}{|A|}$$

A 是 n 阶实对称矩阵

特征值分解

now?

$$A = V \Lambda V^T$$

$$\Lambda = \text{diag} \{ \lambda_1, \dots, \lambda_n \}$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0.$$

$$V = [\vec{v}_1 \dots \vec{v}_n]$$

\vec{v}_i 是 λ_i 所对特征向量.

$$|A| = \prod_{i=1}^n \lambda_i$$

假设 A 对称

X 是 n 维随机向量

$$M = E(X) \quad \Sigma = \text{Var}(X)$$

$$\text{那么 } E(X^T A X) = \text{Tr}(A \Sigma) + M^T A M$$

方差分析

线性回归 线性
变量选择 方法
多重共线性 几大块
聚类

方差分析 Note. 2023.12.7.

她今年只讲了单因子方差分析，没有讲多因子~

二样本独立 t 检验

比较两个方差相等的独立正态分布均值是否相等

样本 1: $x_{11}, x_{12}, \dots, x_{1m}$ \leftarrow 相互独立

样本 2: $x_{21}, x_{22}, \dots, x_{2n}$ \leftarrow

H_0 成立，为 0

样本 1: $N(\mu_1, \sigma^2)$ 2: $N(\mu_2, \sigma^2)$

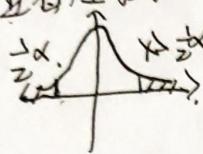
$H_0: \mu_1 = \mu_2$ $H_1: \mu_1 \neq \mu_2$

检验统计量

$$t = \frac{\bar{x}_1 - \bar{x}_2 - 0}{S_{\bar{w}} \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

$$\text{其中 } S_{\bar{w}}^2 = \frac{(m-1)S_x^2 + (n-1)S_y^2}{m+n-2}$$

显著性水平 α 拒绝域



$$|t| \geq t_{1-\frac{\alpha}{2}, m+n-2}$$

$$\text{P 值 } P = 2P(t > |t_0|)$$

这个 t_0 为代入 $\bar{x}, \bar{y}, S_{\bar{w}}$ 算出来的
那个 t 值

若 $P < \alpha$, 说明落入拒绝域
要拒绝； $P \geq \alpha$, 不拒绝
接收

单因子方差分析模型

因子 a 你可以认为有多个组 (多个总体, 比如上面的例子 $a=2$)

重数 ~~数~~ 组 样本量一定，都设为 m 样本总量 $n=am$

样本	响应变量 (观测到的)		总和	均值	$y_{ij} = \bar{y}_i + \bar{y}_j + \bar{y}_{..} + \epsilon_{ij}$
	y_{11}	y_{1m}			
2	y_{21}	\dots	y_{2m}	\bar{y}_2	$\bar{y}_2 = \frac{\bar{y}_i}{m}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
a	\vdots	\vdots	\vdots	\vdots	\vdots

均值模型

$$y_{ij} = \mu_i + \epsilon_{ij}$$

$$i=1 \dots a \quad j=1 \dots m$$

$$\epsilon_{ij} \text{ 随机误差 } E(\epsilon_{ij}) = 0$$

$$E(y_{ij}) = \mu_i \text{ 第 } i \text{ 个水平的均值}$$

效应模型

$$y_{ij} = \mu + \alpha_i + \epsilon_{ij}$$

$$i=1 \dots a \quad j=1 \dots m$$

参数数量多了

$$\text{约束 } \sum \alpha_i = 0$$

$$\mu = \frac{1}{a} \sum \mu_i \text{ 总体均值}$$

都假设 $\epsilon_{ij} \text{ i.i.d } N(0, \sigma^2)$

不同水平波动大小一致的

$$y_{ij} \sim N(\mu + \alpha_i, \sigma^2)$$

假设检验的问题是什么？

(均值模型) $H_0: \mu_1 = \dots = \mu_q$ VS $H_1: \exists i \neq j, i, j \in [1, q]$ 使得 $\mu_i \neq \mu_j$

(效应模型) $H_0: \alpha_1 = \alpha_2 = \dots = \alpha_q = 0$ VS $H_1: \dots$

两种模型等价，怎样检验它们？

平方和分解公式: $SS_T = \sum_{i=1}^q \sum_{j=1}^m (y_{ij} - \bar{y}_{..})^2$

总偏差平方和: $= \sum_{i=1}^q \sum_{j=1}^m ((y_{ij} - \bar{y}_{i.})^2 + (\bar{y}_{i.} - \bar{y}_{..})^2)$

$= \sum_{i=1}^q \sum_{j=1}^m (y_{ij} - \bar{y}_{i.})^2 + \sum_{i=1}^q \sum_{j=1}^m (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^q \sum_{j=1}^m 2(y_{ij} - \bar{y}_{i.})(\bar{y}_{i.} - \bar{y}_{..})$

其中 $2 \sum_{i=1}^q \sum_{j=1}^m (y_{ij} - \bar{y}_{i.})(\bar{y}_{i.} - \bar{y}_{..}) = 2 \sum_{i=1}^q (\bar{y}_{i.} - \bar{y}_{..}) \cdot \left(\sum_{j=1}^m (y_{ij} - \bar{y}_{i.}) \right)$

然后 $\sum_{j=1}^m (y_{ij} - \bar{y}_{i.}) = \sum_{j=1}^m y_{ij} - m \sum_{j=1}^m \bar{y}_{i.} = 0$ 故 $\square = 0$

$SS_T = \sum_{i=1}^q \sum_{j=1}^m (y_{ij} - \bar{y}_{i.})^2 + \sum_{i=1}^q \sum_{j=1}^m (\bar{y}_{i.} - \bar{y}_{..})^2$

$= \sum_{i=1}^q \sum_{j=1}^m (y_{ij} - \bar{y}_{i.})^2 + m \sum_{i=1}^q (\bar{y}_{i.} - \bar{y}_{..})^2$

SS_A 有不同于引发的数据差异又有随机误差的影响

$SS_A \uparrow$ 组间偏差平方和

组内偏差 $SS_E \uparrow$
平方和 (同水平下)

给定了一组数据, SS_T 不变, H_0 成立, SS_A 应该不大。
 SS_A 很大, 说明偏的很厉害拒绝。

检验统计量构造 $\frac{SS_A}{SS_E}$

结论 $\frac{SS_E}{SS_T} \sim \chi^2(n-a)$

取一个水平 $x_1 \dots x_m$ iid $N(\mu, \sigma^2)$
 $\frac{(m-1)S_x^2}{S^2} \sim \chi^2(m-1)$ 然后 χ^2 可加性
有 a 个水平, 放一起, $\frac{a \sum}{S^2} = \frac{SS_E}{SS_T} = \frac{S^2}{S^2} \sim \chi^2(a)$

这就记下来了。

还这样证 (效应模型)

$SS_E = \sum_{i=1}^q \sum_{j=1}^m (y_{ij} - \bar{y}_{i.})^2$
 $= \sum_{i=1}^q \sum_{j=1}^m (\bar{y}_{ij} - \bar{y}_{i.})^2$
样本方差 $(m-1)$

$\bar{y}_{ij} \sim N(0, \sigma^2)$
 $\bar{y}_{i.} = \frac{1}{m} \sum_{j=1}^m \bar{y}_{ij}$
认为是 $\bar{y}_{i1} \dots \bar{y}_{im}$
的样本均值, 再用结论

H_0 成立时, $\frac{SS_A}{S^2} \sim \chi^2(a-1)$

SS_A 与 SS_E 独立

$SS_A = m \sum_{i=1}^q (\bar{y}_{i.} - \bar{y}_{..})^2$
 $= m \sum_{i=1}^q \left(\frac{1}{m} \sum_{j=1}^m (\mu + \alpha_i + \varepsilon_{ij}) - \frac{1}{m} \sum_{j=1}^m (\mu + \alpha_i + \varepsilon_{ij}) \right)^2$
 $= m \sum_{i=1}^q (\alpha_i + \bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..})^2$
 $= m \sum_{i=1}^q (\alpha_i^2 + (\bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..})^2 + 2\alpha_i(\bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..}))$
 $= m \sum_{i=1}^q \alpha_i^2 + m \sum_{i=1}^q (\bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..})^2$
 $= 2m \sum_{i=1}^q \alpha_i(\bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..}) + 2m \sum_{i=1}^q \alpha_i(\bar{\varepsilon}_{i.} - \bar{\varepsilon}_{..})$

$\varepsilon_{ij} \sim N(0, \sigma^2)$

相互独立

$$\text{双项 } E\left(2m \sum_{i=1}^q \alpha_i (\bar{\varepsilon}_{i \cdot} - \bar{\varepsilon}_{..})\right) = 2m \sum_{i=1}^q \alpha_i E(\bar{\varepsilon}_{i \cdot} - \bar{\varepsilon}_{..}) = 0$$

$$\bar{\varepsilon}_{i \cdot} \sim N(0, \frac{f^2}{m}) \quad \bar{\varepsilon}_{..} \sim N(0, \frac{f^2}{n})$$

$$\text{若 } H_0 \text{ 成立 } \alpha_1 = \alpha_2 = \dots = \alpha_q = 0$$

$$E(SS_A) = (q-1)f^2 + m \sum_{i=1}^q \alpha_i^2$$

无论 H_0 是否成立

$$\text{故 } \frac{SS_A}{f^2} \sim \chi^2(q-1)$$

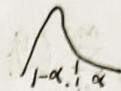
SS_A 与 SS_E 独立 $SS_A \perp SS_E$

$$SS_A = m \sum_{i=1}^q (\alpha_i + \bar{\varepsilon}_{i \cdot} - \bar{\varepsilon}_{..})^2$$

可以是 $\bar{\varepsilon}_{1 \cdot}, \dots, \bar{\varepsilon}_{q \cdot}$ 的函数

$\sum_{j=1}^m (\varepsilon_{ij} - \bar{\varepsilon}_{i \cdot})^2$ 与 $\bar{\varepsilon}_{i \cdot}$ 相互独立, 且 ... 故 SS_A 与 SS_E 独立

$$\text{检验统计量 } F_A = \frac{\frac{SS_A}{q-1}}{\frac{SS_E}{n-q}} \sim F(q-1, n-q)$$



若 $F_A \geq F_{1-\alpha}(q-1, n-q)$ 拒绝 H_0

$$\text{若 } F_A > F_{1-\alpha}(q-1, n-q) \quad \text{因 } F_A = \frac{SS_A}{MS_E} = \frac{SS_A}{\frac{SS_E}{n-q}} = \frac{(q-1)MS_A}{(n-q)MS_E}$$

$$\text{且 } MS_A = \frac{SS_A}{q-1}, \quad MS_E = \frac{SS_E}{n-q}$$

$$\text{P值 } P_A = P(F \geq F_A) \quad \text{若 } P_A < \alpha, \text{ 拒绝 } H_0$$

参数估计是什么? 就是 $M, \alpha_1, \alpha_2, \dots, \alpha_q, f^2 = ?$
 点估计, 极大似然估计结果 $\hat{M} = \bar{y}_{..}$, $\hat{\alpha}_i = \bar{y}_{i \cdot} - \bar{y}_{..}$ (其实 $\hat{M}_i = \bar{y}_i$, $\hat{M}_i = \hat{M} + \hat{\alpha}_i$)

$$\hat{f}^2_{MLE} = \frac{1}{n} \sum_{i=1}^q \sum_{j=1}^m (\bar{y}_{ij} - \bar{y}_{i \cdot})^2 = \frac{SS_E}{n} \quad \text{这样就无偏了.}$$

$$\frac{SS_E}{f^2} \sim \chi^2(n-q) \quad E(SS_E) = (n-q)f^2 \quad \text{故 } \hat{f}^2 = \frac{SS_E}{n-q} = MS_E.$$

$$\text{参数估计, } \bar{y}_{i \cdot} = \frac{1}{m} \sum_{j=1}^m \bar{y}_{ij} = M + \alpha_i + \bar{\varepsilon}_{i \cdot} \sim N(M + \alpha_i, \frac{f^2}{m})$$

$$\frac{SS_E}{f^2} \sim \chi^2(n-q) \quad \bar{y}_1, \bar{y}_2, \dots, \bar{y}_q \text{ 与 } SS_E \text{ 独立.}$$

$$\frac{\sqrt{m}(\bar{y}_{i \cdot} - M_i)}{f}$$

$$t_i = \frac{\sqrt{m}(\bar{y}_{i \cdot} - M_i)}{\sqrt{\frac{SS_E}{f^2(n-q)}}} = \frac{\sqrt{m}(\bar{y}_{i \cdot} - M_i)}{\sqrt{\frac{SS_E}{n-q}}} \sim t(n-q)$$

区间估计 M_i 的 $1-\alpha$ 置信区间

$$[\bar{y}_{i \cdot} - \sqrt{t_{1-\frac{\alpha}{2}}(n-q)} \cdot \hat{f}, \bar{y}_{i \cdot} + \sqrt{t_{1-\frac{\alpha}{2}}(n-q)} \cdot \hat{f}] \quad \hat{f}^2 = \frac{SS_E}{n-q}$$

单因素方差分析模型中，经检验 A 是显著的。（ H_0 检验拒绝原假设）
 ↓ 有充分理由，认为因 A 的各水平中至少存在一对水平的均值不相等
 但这不认定所有水平的均值都不相等

我们想知道哪些水平的均值不相等 一对样本 (i, j)

$$\bar{y}_{i \cdot} \sim N(M_i, \frac{s^2}{m}) \quad \bar{y}_{j \cdot} \sim N(M_j, \frac{s^2}{m}) \quad M_i - M_j \text{ 的区间估计?}$$

$$\bar{y}_{i \cdot} \text{ 和 } \bar{y}_{j \cdot} \text{ 相独立, } \bar{y}_{i \cdot} - \bar{y}_{j \cdot} \sim N(M_i - M_j, \frac{2s^2}{m})$$

但这个分布 s^2 未知，用 $\hat{s}^2 = \frac{SSE}{n-a}$ 代替！但不能简单替换
 替换方法，配凑

$$\frac{(\bar{y}_{i \cdot} - \bar{y}_{j \cdot}) - (M_i - M_j)}{\sqrt{\frac{2}{m}}} \sim N(0, 1)$$

$$\frac{SSE}{\hat{s}^2} \sim \chi^2(n-a)$$

$$\frac{1}{\hat{s}} \cdot \sqrt{\hat{s}^2} \leq \sqrt{\frac{SSE}{\hat{s}^2(n-a)}} \sim \sqrt{\frac{\chi^2(n-a)}{n-a}}$$

$$\text{即 } \frac{(\bar{y}_{i \cdot} - \bar{y}_{j \cdot}) - (M_i - M_j)}{\sqrt{\frac{2}{m}} \cdot \hat{s}} \sim t(n-a)$$

$$\text{置信区间 } (M_i - M_j) \pm \sqrt{\frac{2}{m}} \cdot \hat{s} \cdot t_{1-\frac{\alpha}{2}}(n-a)$$

若这个区间覆盖 0，说明 M_i 和 M_j 无明显差异。

多重比较，因 A 有 a 种水平， $C_{ij}^2 = \frac{\alpha(a-1)}{2}$ 对。

(Bonferroni 方法) 得到的置信区间保守，精度差，但 easy。

将 $t_{1-\frac{\alpha}{2}}(n-a)$ 调整为 $t_{1-\frac{1}{a(a-1)}\alpha}(n-a)$

(Tukey 方法) $H_0: M_i = M_j \quad 1 \leq i < j \leq a$

H_0^{ij} 成立时 $|\bar{y}_{i \cdot} - \bar{y}_{j \cdot}|$ 不应太大，太大就拒绝 H_0^{ij}

拒绝域的形式 $W = \bigcup_{1 \leq i < j \leq a} \{|\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| \geq C_{ij}\} \quad P(W) = \alpha$

求 $(a^2 - a)$ 个 C_{ij} 太难了！对问题进行一些简化。

各水平重复次数 (m) 相等，基于对称性，假设 C_{ij} 统一，记为 C 。

$$P(W) = P\left(\bigcup_{1 \leq i < j \leq a} \{|\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| \geq C\}\right) = 1 - P\left(\bigcap_{1 \leq i < j \leq a} \{|\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| < C\}\right)$$

$$= 1 - m \cdot P\left(\max_{1 \leq i < j \leq a} |\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| < C\right) = P\left(\max_{1 \leq i < j \leq a} |\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| \geq C\right)$$

$$P(\max_{1 \leq i < j \leq n} |\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| \geq c) = P\left(\max_{1 \leq i < j \leq n} \left| \frac{(\bar{y}_{i \cdot} - \bar{y}_{j \cdot}) - (\bar{y}_{i \cdot} - \bar{y}_{j \cdot})}{\frac{\hat{s}}{\sqrt{m}}} \right| \geq \frac{c}{\frac{\hat{s}}{\sqrt{m}}} \right)$$

$$= P\left(\max_{i} \frac{y_{i \cdot} - \bar{y}_{i \cdot}}{\frac{\hat{s}}{\sqrt{m}}} - \min_{i} \frac{y_{i \cdot} - \bar{y}_{i \cdot}}{\frac{\hat{s}}{\sqrt{m}}} \geq \frac{c\sqrt{m}}{\hat{s}}\right)$$

找极差

$$q(a, df) = \uparrow \text{那个极差, 由于 } \frac{\bar{y}_{i \cdot} - \bar{y}_{j \cdot}}{\frac{\hat{s}}{\sqrt{m}}} \sim t(n-a)$$

故 $q(a, df)$ 指 a 个 独立同分布 自由度为 df 的 t 分布 的 随机变量 的 极差

↳ t 所极差统计量 $q(a, n-a)$

算法: 水平数 a , t 分布的自由度 df , 重复次数 N 给定.

↓ 然后, 去求 N 个观测到的 极差 统计量

$$P(w) = \alpha$$

for $n = 1 \rightarrow N$

从 $N(0, 1)$ 产生 a 个随机数 $x_1, x_2 \dots x_a$, $P(w) = P\left(q(a, df) \geq \frac{c}{\hat{s}}\right)$

$x_1 \dots x_a$ sort, $\rightarrow x_{\max} x_{\min}$

再从 df 自由度 χ^2 分布产生随机数 y 可得 $q_{1-\alpha}(a, df) \frac{\hat{s}}{\sqrt{m}} = c$

$$q_n = \frac{x_{\max} - x_{\min}}{\sqrt{y}} \cdot \sqrt{df}$$

注意这里为 $\hat{s} = \sqrt{\frac{SSE}{n-a}}$

知道了 c 值, 若 $|\bar{y}_{i \cdot} - \bar{y}_{j \cdot}| \geq c$, 拒绝 H_0 , 否则...

第1块就结束了, 开始第2块: 多元线性回归 (今年没讲 - 无)

线性回归模型: $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon$.

y 因变量

自变量

$$\begin{bmatrix} \beta_0 \\ \vdots \\ \beta_p \end{bmatrix}$$

未知参数

P+1 维

随机误差

$$E(\varepsilon) = 0$$

$$\text{Var}(\varepsilon) = \sigma^2$$

n 组观测数据

$$y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

$$x = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}$$

$$\beta = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_p \end{bmatrix}$$

$$\varepsilon = \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

假定

$$\text{rank}(x) = p+1 < n$$

(自变量之间不相关)

样本量 $n > \text{自变量}$

满足秩! (个数 $(p+1)$)

$$y = x\beta + \varepsilon, \quad \beta \text{ 如何估计?}$$

$$E(\varepsilon_i) = 0 \quad i = 1, 2, \dots, n \text{ 无系统误差}$$

$$\text{cov}(\varepsilon_i, \varepsilon_j) = \begin{cases} \sigma^2, & i=j \\ 0, & i \neq j \end{cases}$$

$$\varepsilon \sim N(\vec{0}, \sigma^2 I_n)$$

$$\varepsilon_1, \dots, \varepsilon_n \text{ 相互独立, } E(y) = x\beta, \text{Var}(y) = \sigma^2 I_n$$

最小二乘估计.

离差
观侧
估计.

离差最小化

$$\hat{\beta}_{LS} = \arg \min_{\beta} \sum_{i=1}^n (y_i - x_i^T \beta)^2.$$

$$\sum_{i=1}^n (y_i - x_i^T \beta)^2 = \|y - X\beta\|^2 = (y - X\beta)^T (y - X\beta) = \beta^T X^T X \beta - 2\beta^T X^T y + y^T y$$

$$\|X\|^2 = X^T X$$

根据可得 $\hat{\beta}_{LS} = (X^T X)^{-1} X^T y$, 这就是最小二乘估计的值.

但是这个能直接拿用吗? No! $(X^T X)^{-1}$ 必须有在, 即 $\text{rank}(X^T X) \neq 0$.

$$X \in \mathbb{R}^{m \times (p+1)} \quad X^T X \text{ 为 } p+1 \text{ 阶满秩阵. } \text{rank}(X^T X) = p+1. \text{ 那么}$$

$$X \text{ 为 } n \times (p+1) \text{ 阵, 故 } n \geq p+1$$

$$\text{rank}(X) \geq \text{rank}(X^T X) = p+1$$

[样本量大于参数量]

$$\text{回归值/拟合值. } \hat{y} = X\hat{\beta} = \frac{X(X^T X)^{-1} X^T y}{= H \text{ 帽矩阵.}}$$

$$\text{残差? 实际与估计之差 } e = y - \hat{y} = (I - H)y$$

$$\hat{y}^T e = (Hy)^T (I - H)y = y^T H^T (I - H)y = 0 \quad \text{回归值 } \hat{y} \text{ 与 } e \text{ 垂直}$$

$$\begin{aligned} \text{Var}(e) &= \text{cov}(e, e) = (I - H) \text{cov}(y, y) (I - H)^T \\ &= (I - H) \cdot \underbrace{\sum_{i=1}^n (I - H)^T}_{(I - H)^T = (I - H)} = \underbrace{\sum_{i=1}^n (I - H)^T}_{(I - H)^T = (I - H)} (I - H)^T \quad \text{故该式} = f^2(I - H) \end{aligned}$$

$$\text{方差 } \sigma^2 \text{ 的估计? } \hat{\sigma}_{LS}^2 = \frac{1}{n-p-1} (e^T e) = \frac{1}{n-p-1} \sum_{i=1}^n e_i^2.$$

$$\begin{aligned} \text{为什么?} \quad \text{因为 } I - H \text{ 中 } I \text{ 为 } n \times n \text{ 阵. } \text{rank}(I - H) &= \text{Tr}(I - H) \\ &= \text{Tr}(I) - \text{Tr}(H) \\ &= n - (p+1) = n - p - 1 \end{aligned}$$

极大似然估计.

$$y \sim N_n(X\beta, \sigma^2 I_n)$$

$$y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \text{ 联合密度函数为 } f(y|\beta, \sigma^2) = \frac{1}{(2\pi)^{\frac{n}{2}} |\sigma^2 I_n|^{\frac{1}{2}}} \cdot \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta) \right\}$$

$$\text{似然函数为 } (2\pi)^{-\frac{n}{2}} (\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta) \right\}$$

$$\cdots \text{ 极大似然估计 } \hat{\beta}_{ML} = (X^T X)^{-1} X^T y = \hat{\beta}_{LS} = \hat{\beta} \text{ 记作.}$$

$$\text{但是 } \hat{\sigma}_{ML}^2 = \frac{1}{n} (e^T e) \quad \hat{\sigma}_{ML}^2 \text{ 有偏, 但 } \hat{\sigma}_{LS}^2 \text{ 无偏}$$

$$\star \text{ 对 } \hat{\beta} = (X^T X)^{-1} X^T y 而言. \quad E(\hat{\beta}) = \beta. \quad \text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$$

$$\begin{aligned} E(\hat{\beta}) &= E((X^T X)^{-1} X^T y) = (X^T X)^{-1} X^T E(y) = (X^T X)^{-1} X^T E(X\beta + \varepsilon) \\ &= (X^T X)^{-1} X^T (X\beta + E(\varepsilon)) = (X^T X)^{-1} X^T X\beta = \beta \end{aligned}$$

$$\text{Var}(\hat{\beta}) = \text{Var}((X^T X)^{-1} X^T y) = (X^T X)^{-1} X^T \cdot \text{Var}(y) \cdot X (X^T X)^{-1}$$

$$= (X^T X)^{-1} X^T \cdot \sigma^2 I \cdot X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

★ 还有些性质，如 $\hat{\beta}$ 和 e 线性不相关

$$\text{Cov}(\hat{\beta}, e) = 0. \quad (\text{正态分布假定下, } \hat{\beta} \text{ 与 } e \text{ 独立, 此时 } \hat{\beta} \text{ 与 } \text{SSE} = e^T e \text{ 也独立})$$

$$\text{Cov}(\hat{\beta}, e) = \text{Cov}((X^T X)^{-1} X^T y, (X^T X)^{-1} X^T e) = \sigma^2 (X^T X)^{-1} X^T \cdot (I - H)$$

$$= \sigma^2 \left((X^T X)^{-1} X^T - (X^T X)^{-1} X^T X (X^T X)^{-1} X^T \right) = \sigma^2 \cdot 0 = 0$$

中心化和标准化, 请大致清楚推证方法, 具体细节不用管.

$$\text{原模型: } \hat{y}_i = X_i^T \beta + \varepsilon = \beta_0 + \sum_{j=1}^p \beta_j \cdot X_{ij} + \varepsilon.$$

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} \rightarrow \begin{array}{l} \beta_{\text{intercept}} \\ \beta_{\text{slope}} \end{array} \quad \hat{y}_i = \hat{\beta}_{\text{intercept}} + X_i^T \hat{\beta}_{\text{slope}},$$

$$\text{原始: } y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \quad X = [I_n \ X_0] \quad X_0 = [x_1 \ \dots \ x_p]$$

$$\text{中心化: } y^* = \begin{bmatrix} y_1^* \\ \vdots \\ y_n^* \end{bmatrix} \quad X^* = [I_n \ X_C] \quad X_C = [x_1^* \ \dots \ x_p^*]$$

$\star X_C = (I_n - H_{I_n}) X_0$

$H_{I_n} = I_n (I_n^T I_n)^{-1} I_n$

$\hat{\beta}_{\text{intercept}} = 0$

$\hat{\beta}_{\text{slope}} = \hat{\beta}_{\text{slope}}$

$X_i \downarrow$ 也是这个方向进行

$$y_i^* = y_i - \bar{y} \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

$$x_{ij}^* = x_{ij} - \bar{x}_j \quad \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

$$I_n^T (I_n - H_{I_n}) = 0$$

$$\text{标准化: } \begin{array}{c} \boxed{\text{原图}} \\ \downarrow \quad \text{也是这个方向进行} \end{array} \quad x_{ij}^{**} = \frac{x_{ij}^*}{\sqrt{L_{ij}}} \quad L_{ij} \text{ 是 } x_j \text{ 的离差平方和.}$$

$$y_i^{**} = \frac{y_i^*}{\sqrt{L_{yy}}} \quad L_{yy} = \sum_{j=1}^n (x_{ij} - \bar{x}_j)^2$$

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

$$y^{**} = \frac{1}{\sqrt{L_{yy}}} y^* \quad X_S = X_C L \quad L = \left[\frac{1}{\sqrt{L_{11}}} \ \dots \ \frac{1}{\sqrt{L_{pp}}} \right]$$

$$x_{ij} = (I - H_{I_n}) x_0 L$$

$$\hat{\beta}_{S, \text{intercept}} = 0$$

$$\hat{\beta}_{S, \text{slope}} = \frac{1}{\sqrt{L_{yy}}} L^{-1} \hat{\beta}_{C, \text{slope}} = \frac{1}{\sqrt{L_{yy}}} L^{-1} \hat{\beta}_{S, \text{slope}}$$

每个分量 $\hat{\beta}_{Sj} = \frac{\sqrt{L_{jj}}}{\sqrt{L_{yy}}} \hat{\beta}_{Cj}$

$$\begin{aligned}
 \hat{\beta} &= (X^T X)^{-1} X^T y = \begin{bmatrix} n \cdot I_n^T X_0 \\ X_0^T I_n \end{bmatrix}^{-1} \begin{bmatrix} I_n^T \\ X_0^T \end{bmatrix} y \\
 X &= [I_n \ X_0] \\
 X_0 &= [x_1 \ \dots \ x_p] \\
 X^T X &= \begin{bmatrix} I_n^T \\ X_0^T \end{bmatrix} \begin{bmatrix} I_n & X_0 \end{bmatrix} \\
 &= \begin{bmatrix} I_n^T I_n & I_n^T X_0 \\ X_0^T I_n & X_0^T X_0 \end{bmatrix}
 \end{aligned}$$

$$\begin{aligned}
 &= \begin{bmatrix} \frac{1}{n} + \frac{1}{n^2} I_n^T X_0 A_0 X_0^T I_n & -\frac{1}{n} I_n^T X_0 A_0 \\ -\frac{1}{n} A_0 X_0^T I_n & A_0 \end{bmatrix} \begin{bmatrix} I_n^T \\ X_0^T \end{bmatrix} y \\
 &= \begin{bmatrix} \frac{1}{n} I_n^T + \frac{1}{n^2} I_n^T X_0 A_0 X_0^T I_n I_n^T - \frac{1}{n} I_n^T X_0 A_0 X_0^T \\ -\frac{1}{n} A_0 X_0^T I_n I_n^T + A_0 X_0^T \end{bmatrix} y
 \end{aligned}$$

$$\text{其中 } A_0 = (X_0^T X_0 - \frac{1}{n} X_0^T I_n I_n^T X_0)^{-1}$$

然后中心化，走一波类似的操作， X_C 换 X_0 。
 $A_C = (X_C^T X_C - \frac{1}{n} X_C^T I_n I_n^T X_C)^{-1} = A_0$

$$\beta_{\text{intercept}} = (\frac{1}{n} I_n^T + \frac{1}{n^2} I_n^T X_0 A_0 X_0^T I_n I_n^T - \frac{1}{n} I_n^T X_0 A_0 X_0^T) y$$

$$\beta_{\text{slope}} = (-\frac{1}{n} A_0 X_0^T I_n I_n^T + A_0 X_0^T) y \quad \text{可证... 具体过程skip}$$

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2)$$

这个模型中， y 与 $x_1 \dots x_p$ 是否有明显线性关系？ \rightarrow 检验回归方程 (F检验)

若有在， $\beta_0 \dots \beta_p$ 这些回归系数显著性如何？ \rightarrow t检验。

F检验 (看回归方程) $\rightarrow H_0$ 成立 y 与 $x_1 \dots x_p$ 间用线性模型刻画不合理

$$H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0 \quad \text{vs} \quad H_1: \text{有在 } \beta_j \neq 0 \ (j=1, \dots, p)$$

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

离差方和。

$$\text{正态假设下, } \frac{SSE}{\sigma^2} \sim \chi^2(n-p-1) \quad SSE = e^T e.$$

$$y \sim N(X\beta, \sigma^2 I_n) \quad \text{若 } H_0 \text{ 成立} \quad \frac{SSR}{\sigma^2} \sim \chi^2(p) \quad \text{检验量 } F_0 = \frac{\frac{SSR}{p}}{\frac{SSE}{n-p-1}} \quad \text{证明略}$$

$$SSE = e^T e = y^T (I - H) y$$

$$y \sim N(X\beta, \sigma^2 I_n) \quad \text{rank}(I - H) = n - p - 1$$

$$\frac{1}{\sigma^2} [E(y)]^T (I - H) E(y) = 0$$

$$\text{故 } \frac{SSE}{\sigma^2} \sim \chi^2(n-p-1)$$

(看P4的结论) ①若 $F_0 > F_{\alpha}(p, n-p-1)$ ②若 $F_0 = P(F \geq F_0) < \alpha$, 拒绝 H_0 .

$$\begin{cases} SSR = y^T H (I - H_{1n}) H y \\ = y^T (H - H_{1n}) y \\ H H_{1n} = H_{1n} = H_{1n} H \end{cases}$$

来源	平方和	自由度	均方	F值	$SS_T = y^T (I_n - H_{1n}) y$
回归	SS_R	P	$\frac{SS_R}{P}$	$F_0 = \frac{\frac{SS_R}{P}}{\frac{SS_E}{n-P-1}}$	$SS_R = y^T (H - H_{1n}) y$
误差	SS_E	$n-P-1$	$\frac{SS_E}{n-P-1}$		$SS_E = y^T (I_n - H) y$
总和	SST	$n-1$			

t检验 检验的问题：哪个 β_j 有意义？

$H_0: \beta_j = 0 \quad j=1, 2, \dots, P \quad \text{vs} \quad H_1: \exists j \text{使得 } \beta_j \neq 0$

$\hat{\beta}_j \sim N(\beta_j, C_{jj} \hat{\sigma}^2)$ 检验统计量 $t_j = \frac{\hat{\beta}_j}{\sqrt{C_{jj} \hat{\sigma}^2}}$

$$\text{其中 } \hat{\sigma}^2 = \frac{1}{n-P-1} SSE.$$

H_0 成立时, $\beta_j = 0 \quad t_j \sim t(n-P-1)$ 若 $|t_j| \geq t_{1-\frac{\alpha}{2}}(n-P-1)$ 拒绝 H_0
认为 β_j 显著不为 0

一元线性回归中, t 和 F 检验等价
拟合优度 \rightarrow 度量回归方程对样本观测值的拟合程度
多元不等价。

样本决定系数 $R^2 = \frac{SS_R}{SS_T} = 1 - \frac{SS_E}{SS_T} \in [0, 1]$ 越接近 1 说明回归拟合效果好

复相关系数 $R = \sqrt{R^2}$ 衡量作为一个整体的 $X_1 \dots X_P$ 与 y 线性关系

相关系数衡量的是单个随机变量 X_j 与 y 线性关系

给定 $X_0 = [1 \quad X_1 \quad \dots \quad X_P]^T$ 我们关心的是 $y_0 = X_0^T \beta + \varepsilon_0$

基本假定 $E(\varepsilon_0) = 0 \quad \text{Var}(\varepsilon_0) = \sigma^2 \quad E(y_0) = X_0^T \beta \quad \text{Var}(y_0) = \sigma^2$

点预测 $\hat{y}_0 = X_0^T \hat{\beta}$ 如何判断 \hat{y}_0 的好坏？我们的指标 $E(\hat{y}_0 - y_0)^2$

$E(\hat{y}_0 - y_0)^2 = \text{Var}(\hat{y}_0) + \text{Bias}^2(\hat{y}_0) + \text{Var}(\varepsilon_0)$ (中间省略许多)
[\hat{y}_0 是 y_0 无偏预测] $E(\hat{y}_0) = E(y_0)$
 $\text{Bias}^2(\hat{y}_0) = 0$

y_0 是 \hat{y}_0 的线性函数，故 \hat{y}_0 是 y_0 线性预测
在 y_0 所有线性无偏预测中，
 \hat{y}_0 是否 best?

$\hat{\beta}$ 是 β 的 LS 估计 对任意 C 来说 $C^T \hat{\beta}$ 是 $C^T \beta$ 的最小方差线性无偏估计
↓ y_0 的一切线性无偏预测中， \hat{y}_0 的方差最小！

$\hat{y}_0 - y_0 \sim N(0, \sigma^2 (I_n - X_0^T (X_0 X_0^T)^{-1} X_0))$

$\hat{y}_0 - y_0$ 与 $\hat{\sigma}^2$ 相互独立

原因：
 $y \sim N_n(X\beta, \sigma^2 I_n)$
 $\hat{\beta} \sim N_p(\beta, \sigma^2 (X^T X)^{-1})$

$\hat{y}_0 \sim N(X_0^T \hat{\beta}, \sigma^2 X_0^T (X^T X)^{-1} X_0)$

$y_0 \sim N(X_0^T \beta, \sigma^2)$

$$\frac{SSE}{s^2} \sim \chi^2(n-p-1)$$

$$\hat{y}_0 - y_0 \sim N(0, s^2(1 + x_0^T (X^T X)^{-1} x_0))$$

$$\hat{y}_0 - y_0$$

$$\text{这个 } \hat{s}^2 = \frac{1}{n-p-1} SSE$$

$$\frac{\hat{s}}{\sqrt{1 + x_0^T (X^T X)^{-1} x_0}} \sim t(n-p-1)$$

$$y_0 \text{ 的 } 1-\alpha \text{ 置信区间: } \hat{y}_0 \pm t_{1-\frac{\alpha}{2}}(n-p-1) \cdot \hat{s} \sqrt{1 + x_0^T (X^T X)^{-1} x_0}$$

$$E(y_0) \text{ 的 } 1-\alpha \text{ 置信区间: } \hat{y}_0 \pm t_{1-\frac{\alpha}{2}}(n-p-1) \cdot \hat{s} \sqrt{1 + x_0^T (X^T X)^{-1} x_0}$$

马上就要开始接下来的重要内容, 我括一句题外话

就是川在11.7说GUM推导过程不作为理论作业, 但不妨碍期末考,

变量选择: 其实就研究欠拟合和过拟合现象

欠拟合: 模型预测偏差大, 拟合不足, 失去重要变量

过拟合: 容纳了过多的不重要变量, 预测能力差, 过度拟合

自变量选择笨方法: 全子集回归 P 个自变量 1个一组 ($C_P^1 = P$)

$$\sum_{k=1}^P C_P^k = 2^P$$

将 P 个自变量纳入模型: 全模型 $y = X_P \beta_P + \varepsilon$

从 P 个自变量中选 P_1 个 ($P_1 < P$)

选模型 为简化

$$y = X_{P_1} \beta_{P_1} + \varepsilon$$

就认为 $x_1 \dots x_{P_1}$ 是 $x_1 \dots x_P$ 的前 P_1 个

$$X_P = \begin{bmatrix} 1 & x_1 & \dots & x_{1P} \\ 1 & x_2 & \dots & x_{2P} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & \dots & x_{nP} \end{bmatrix}$$

$$X_{P_1} = \begin{bmatrix} 1 & x_{11} & \dots & x_{1P_1} \\ 1 & x_{21} & \dots & x_{2P_1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nP_1} \end{bmatrix}$$

if 全模型正确, 却使用选模型, 欠拟合

if 选模型 true, 却 use 全~, 过拟合

$$\text{全模型时, } \hat{\beta}_P = (X_P^T X_P)^{-1} X_P^T y$$

$$\hat{s}_P^2 = \frac{SSE}{n-p-1}$$

参数估计

$$\text{在 } X_{P_1} \text{ 时预测值 } \hat{y}_0 = X_{P_1}^T \hat{\beta}_P$$

$$SSE_P = (y - \hat{y}_P)^T (y - \hat{y}_P)$$

选模型与之类似, 把 P 用 P_1 换即可

$$\text{假设全模型 true, } y = X_P \beta_P + \varepsilon = [X_{P_1} \ Z] \begin{bmatrix} \beta_{P_1} \\ \vdots \\ \beta_{P_1} \end{bmatrix} + \varepsilon$$

$$= X_{P_1} \beta_{P_1} + Z \gamma + \varepsilon$$

去使用选模型
($y = X_{P_1} \beta_{P_1} + \varepsilon$)

失去信息
 $\text{rank}(X_P) > \text{rank}(X_{P_1})$
 $\gamma \neq 0_{P-p}$ 14

因为我们错误地选了模型，所以我们使用的参数估计

$$\hat{\beta}_{P1} = (X_{P1}^T X_{P1})^{-1} X_{P1}^T y \quad \hat{s}_{P1}^2 = \frac{1}{n - p_1 - 1} SSE^{P1} \quad \text{预测值} \\ \hat{y}_0 = X_{P1}^T \hat{\beta}_{P1}$$

$$E(\hat{\beta}_{P1}) = (X_{P1}^T X_{P1})^{-1} X_{P1}^T E(y) = \boxed{\quad} E(X_{P1} \beta_{P1} + ZY + \varepsilon) \\ = \boxed{\quad} (X_{P1} \beta_{P1} + ZY + E(\varepsilon)) \quad \text{why} \\ = \boxed{\quad} (X_{P1} \beta_{P1} + ZY) = \beta_{P1} + (X_{P1}^T X_{P1})^{-1} X_{P1}^T ZY.$$

由于 $Y \neq 0$ $\hat{\beta}_{P1}$ 有偏 但假如 $X_{P1}^T Z = 0$, $\hat{\beta}_{P1}$ 就无偏了！
通常认为有偏！

$$SSE^{P1} = y^T (I - H_{XP}) y \quad SSE^P = y^T (I - H_{XP}) y \\ H_{XP} = X_P (X_P^T X_P)^{-1} X_P^T = [X_{P1} \quad Z] \begin{bmatrix} X_{P1}^T X_{P1} \\ Z^T X_{P1} \end{bmatrix}^{-1} \begin{bmatrix} X_{P1}^T \\ Z^T \end{bmatrix}$$

$$H_{XP} = \frac{H_{XP1} + N_{XP} \otimes I}{H_{XP1} + \text{一大串}} \Rightarrow \text{故 } SSE^{P1} = SSE^P + \text{一大堆} \\ E(SSE^{P1}) = E(SSE^P) + E(\text{一大堆}) = \dots \\ = (n - p_1 - 1) s^2 + Z^T Z^T N_{XP} Z Y.$$

$$E(\hat{s}_{P1}^2) = \frac{1}{n - p_1 - 1} E(SSE^{P1}) = s^2 + \frac{\dots}{n - p_1 - 1} > s^2.$$

可以看到 \hat{s}_{P1}^2 有偏！
又是一大堆推导 (skip) 结论 全模型 time 但错用选模型时
预测值 $\text{Var}(\hat{y}_0)$ 比真实值 $\text{Var}(y_0)$ 更小！

过拟合推导也类似, skip!

大结论	欠拟合	过拟合	$\hat{\beta}_{P1}, 0^T$!
点估计	$\hat{\beta}_P$ 有偏 \hat{s}_P^2 有偏	$\hat{\beta}_{P1}$ 无偏 \hat{s}_{P1}^2 无偏	自变量数量过多
预测	有偏预测 (y_0 有偏) $\text{Var}(\hat{y}_0)$ 更小	无偏预测 (\hat{y}_0 无偏) $\text{Var}(\hat{y}_0)$ 更大	预测值偏差 但会引起 较大波动

但有可能欠拟合
误差更小

预测值偏差
但会引起
较大波动

自变量选择准则 一个变量都两种情况 [选不选] 2种情况

SSE 和 R^2 . 常用衡量模型拟合数据的好坏
残差平方和 离差数 它们是否能用于选择自变量? ans: No!

$$SSE_{P_1} = y^T (I_n - H_{P_1}) y \quad SSE_{P_1+1}$$

$$\text{关系: } SSE_{P_1+1} \leq SSE_{P_1}$$

自变量个数少, 残差平方和少.

$$R^2 = \frac{SST}{SST} = 1 - \frac{SSE}{SST}$$

SST 不变

(给定 dataset)

故关系 $R^2_{P+1} \geq R^2_{P_1}$
自变量个数少, R^2 增大.

reason

那我们如何作为变量选择的 metric?

① 修正 $R^2 \rightarrow \tilde{R}^2 = 1 - \frac{n-1}{n-p-1} (1-R^2) \quad \tilde{R}^2 \leq R^2$

\tilde{R}^2 随自变量个数不一定少, 因为有惩罚项.

$$S^2 \text{ 无偏估计 } \hat{S}^2 = \frac{1}{n-p-1} SSE.$$

② 赤化信息量 $AIC = -2 \ln(\text{模型极大似然}) + 2(\text{模型独立参数个数})$

$$\text{线性模型中 } AIC = -2 \ln\left(\left(2\pi e \frac{SSE}{n}\right)^{-\frac{n}{2}}\right) + 2(P+1)$$

$$\downarrow \text{Why? } \propto n \ln\left(\frac{SSE}{n}\right) + 2(P+1)$$

取 AIC 最小者! 就是最优

③ 贝叶斯信息量 $BIC = -2 \ln(\text{模型极大似然}) + \ln(n) (\text{模型独立参数个数})$

$$\text{线性模型 } BIC = n \ln\left(\frac{SSE}{n}\right) + \ln(n)(P+1)$$

取 BIC 最小者! 就是最优

④ 马洛斯统计量. 用预测的角度选自变量.

$$\hookrightarrow (P = \frac{SSE^P}{S^2} - n + 2(P+1) = (n-P-1) \frac{SSE^P}{S^2} - n + 2(P+1)$$

选 $(P$ 最小的子集.

还可以逐步回归 先确定准则 (如 AIC)

→ 前进法 \rightarrow 自变量有进有出
开始显着之后

再从最小的模型开始 (从 $x_1 \dots x_p$ 中确定放入 model)

再确定一个 $x_i, i=2 \dots p$ 放入 model 以此类推. 逐剔

逐进
逐出

后退法 → 类似前进法, 不过是在剔元素. → 缺点: 最初计算量很大, 剔出了就回不来了.

逐步回归：自变量一个个引入，引入时对已选入的变量逐个确包
 若之前引入的自变量因当前自变量引入而导致模型不再优化，将其剔除
 反复执行直到加入其他任何一个自变量，模型并不会更优，stop
 或剔除
 (多重共线性)

最小二乘估计 $\hat{\beta} = (X^T X)^{-1} X^T y$ 若 $x_1 \dots x_p$ 完全线性相关 $|X^T X| = 0$

这样无法最小二乘估计 $\hat{\beta}$ 相关程度很高时， $|X^T X| \approx 0$

可得 $\hat{\beta} = \hat{\beta}^2 (X^T X)^{-1}$ 精度很低

自变量间完全不相关情形很少见

若有多个自变量，若自变量间相关性弱

认为符合多元线性回归模型假设

比如就两个自变量

β_1 β_2

若 β_1 和 β_2 相关性↑

$Var(\hat{\beta}_1) \uparrow$ $Var(\hat{\beta}_2) \uparrow$

否则，认为不符号

可能有过多虚拟变量 $x_m = 1$ (男性) $x_f = 1$ (女性)

$x_f = 1 - x_m$

若丁分类，至多可设置丁-1个虚拟变量

(某变量由其他变量计算而成)

度量收入与压力关系，收入 [个人收入] $\xrightarrow{\text{主成分分析}}$ 合并收入，并以此为自变量

多重共线性诊断

方差扩大因子法
特征值判定法
直观判定法

方差扩大因子

$X = [x_1 \dots x_p]$ 作标准化，记为 x_s

相关系数 $x_s^T x_s = R$ $C = R^{-1} = (x_s^T x_s)^{-1}$

矩阵 C 的主对角线元素 C_{ii} 为自变量 x_i 的

方差扩大因子

在对 y 和 $x_1 \dots x_p$ 均进行标准化后

$\hat{\beta}_{s,j} = \frac{\sqrt{L_{jj}}}{\sqrt{L_{jj}}} \hat{\beta}_j$
使用矩阵

这里 我们仅考察对 $x_1 \dots x_p$ 标准化

$\hat{\beta}_{s,j} = \sqrt{L_{jj}} \hat{\beta}_j$

$Var(\hat{\beta}_j) = \frac{C_{jj}}{L_{jj}} s^2$

$C_{jj} \uparrow$ $\hat{\beta}_j$ 的 Var 也↑

$L_{jj} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$

我们若将 x_j 作为因变量，与其他 $p-1$ 个自变量建多元线性回归模型。

R_j^2 为其复决定系数 $\left[C_{jj} = \frac{1}{1 - R_j^2} \right]$ 作业题。

R_j^2 越大 C_{jj} 小，多重共线性较大。

说明 x_j 与其余自变量线性相关程度也更大。

取一个 C_{VIF} (Wels, 10, 100) 若 $VIF_j < C_{VIF}$ ，认为 x_j 与其余自变量不存

多重~。

如何度量整个矩阵多重共线性？

否则~。

$\bar{VIF} = \frac{1}{p} \sum_{j=1}^p VIF_j$ VIF 大时 表示有...
样本小时 VIF 易很大 \rightarrow 因此要结合样本量讨论

特征值判定法

x 经过标准化

$|x^T x| \approx 0$ 时 $x^T x$ 至少有一个特征值近似于 0

$x^T x$ 特征值为 $\lambda_1 \geq \lambda_2 \dots \geq \lambda_p$ 取 $k_j = \sqrt{\frac{\lambda_1}{\lambda_j}}$ 为条件数

最小特征值 λ_p 对条件数 $k_p = \sqrt{\frac{\lambda_1}{\lambda_p}}$ 若 k_p 很大，则 x 有在多重共线性。

否则 ... x 不存在...

若 $0 < k_p < C_k$ 时 x 不存在... 否则 x 有在 (C_k 常取 10, 100, 1000)

直观判定法 增/删一个自变量时 其他自变量 回归系数估计值/显著性发生较大变化。

存在严重~。

若定性分析认为重要自变量，在回归方程中从未通过显著性检验

初步认为，存在严重~。

若与因变量间简单相关系数绝对值较大

的自变量，在回归方程中未通过显著性检验

还有一些 若...，判定...，此处不详说，见 slides!

消除多重共线性 ① 删不重要变量 ② 增样本量 n ③ 改进经典最小二乘估计

假设 x 标准化了， y 未标准化。

岭回归 主成分回归

改进一下传统最小二乘估计

$$\hat{\beta} = (x^T x)^{-1} x^T y$$

\downarrow 用 $x^T x + kI$ ($k > 0$) 代替 $x^T x$

k 较小时 $x^T x + kI \approx x^T x$ 且 $x^T x + kI$ 逆矩阵。

$\hat{\beta}(k) = (X^T X + kI)^{-1} X^T y$ 为 β 的岭回归估计, k :岭参数
 X 已经标准化 $X^T X$ 就是自变量样本的相关系数矩阵
 k 不唯一确定!

性质① $\hat{\beta}(k)$ 是 β 的有偏估计

$$E(\hat{\beta}(k)) = E((X^T X + kI)^{-1} X^T y) = (X^T X + kI)^{-1} X^T E(y) \\ = (X^T X + kI)^{-1} X^T X \beta \neq \beta.$$

性质② $\hat{\beta}(k)$ 与 $\hat{\beta}(0)$ (最小二乘估计) 什么关系?

$$\hat{\beta}(k) = (X^T X + kI)^{-1} \underbrace{X^T y}_{\hat{y}} = (X^T X + kI)^{-1} (X^T X) \underbrace{(X^T X)^{-1} X^T y}_{\hat{\beta}(0)}$$

看似 $\hat{\beta}(k)$ 是 $\hat{\beta}$ 的一种线性变换. 但实际 k 由数据确定
 $(\hat{\beta}(k))$ 并非 $\hat{\beta}$ 的线性变换
 $(\hat{\beta}(k))$ 也并非 y 的线性函数)

性质③ ~~岭回归~~ $\hat{\beta}(k)$ 是否比 $\hat{\beta}(0)$ 更优?

用 均方误差 作为指标

$\exists k > 0$. 使得. $MSE(\hat{\beta}(k)) \leq MSE(\hat{\beta}(0))$ 证明见 slides, 略!

$$MSE(\hat{\beta}(k)) = E((\hat{\beta}(k) - \beta)^T (\hat{\beta}(k) - \beta))$$

$X^T X$ 特征值 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_P \geq 0$ 特征向量 $v_1 \dots v_P$

$$\left\{ \begin{array}{l} (X^T X) v_j = \lambda_j v_j \quad j = 1 \dots P \\ (X^T X + kI) v_j = (X^T X) v_j + k v_j = \lambda_j v_j + k v_j = (\lambda_j + k) v_j \end{array} \right.$$

$$\text{故 } (X^T X + kI)^{-1} v_j = \frac{1}{\lambda_j + k} v_j$$

k 的选取与 β 都有关; 无法找一个一一对应的 k 使得 $MSE(\hat{\beta}(k))$

另角度看岭回归.

最小二乘估计: $\hat{\beta} = \arg \min_{\beta} (y - X\beta)^T (y - X\beta)$

① 若最小二乘估计 $\hat{\beta}^T \hat{\beta} \leq s$
 $\hat{\beta}$ 就是我们想要的

岭回归估计 (加上) 正则项)

② 若 $\hat{\beta}^T \hat{\beta} > s$
 $\hat{\beta}(k)^T \hat{\beta}(k) \leq s < \hat{\beta}^T \hat{\beta}$.

$$\hat{\beta}(k) = \arg \min_{\beta} (y - X\beta)^T (y - X\beta) + k \beta^T \beta$$

$$\left\{ \begin{array}{l} \text{等价于 } \arg \min_{\beta} (y - X\beta)^T (y - X\beta) \\ \text{s.t. } \beta^T \beta \leq s \end{array} \right.$$

性质④ 对 $\forall k > 0$, $||\hat{\beta}|| \neq 0$ 总有 $||\hat{\beta}(k)|| < ||\hat{\beta}||$

$X^T X$ 特征值 $\lambda_1 \cdots \lambda_p$, $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$, $v_1 \cdots v_p$ 特征向量

$$X^T X = V^T \Lambda V, \quad y = X \beta + \varepsilon = X V^T \hat{\beta} + \varepsilon = Z \hat{\alpha} + \varepsilon.$$

$$\hat{\alpha} = V \hat{\beta} \text{ 可得 } \beta = V^{-1} \hat{\alpha} = V^T \hat{\alpha}.$$

$$\hat{\alpha} = \underbrace{(Z^T Z)^{-1} Z^T y}_{\text{why?}} = (V X^T V^T)^{-1} Z^T y = (V V^T V V^T)^{-1} Z^T y = \Lambda^{-1} Z^T y$$

$$\hat{\beta} = V \hat{\beta} = (X^T X)^{-1} X^T y = V^T \Lambda^{-1} V X^T y = V^T \hat{\alpha}.$$

$$\hat{\alpha}(k) = (\Lambda + kI)^{-1} Z^T y \quad \hat{\beta}(k) = V^T \hat{\alpha}(k)$$

$$\text{故 } ||\hat{\beta}(k)|| = ||\hat{\alpha}(k)|| = ||(\Lambda + kI)^{-1} \Lambda \hat{\alpha}|| < ||\hat{\alpha}|| = ||\hat{\beta}||$$

乘以 Λ 不改变范数

$\hat{\beta}(k)$ ~~是 $\hat{\beta}$ 向原点的压缩~~ $MSE(\hat{\beta}) = E((\hat{\beta} - \beta)^T (\hat{\beta} - \beta))$

$$= E(\hat{\beta}^T \hat{\beta}) - \beta^T \beta$$

$$\text{故 } E||\hat{\beta}||^2 = ||\beta||^2 + MSE(\hat{\beta}) = E||\hat{\beta}||^2 - ||\beta||^2.$$

$$= ||\beta||^2 + \delta^2 \sum_{j=1}^p \lambda_j^{-1}$$

\times 出现多重共线性时, $\delta^2 \sum_{j=1}^p \lambda_j^{-1}$ 较大, 对其就该做压缩!

k 的选择 ① 岭迹法 取一个 k , $\hat{\beta}(k) = (X^T X + kI)^{-1} X^T y$ 的第 j 个分量 $\hat{\beta}_j(k)$
 $k \in [0, +\infty)$ 时, $\hat{\beta}_j(k)$ 的图像为岭迹!

看什么时候各岭迹基本稳定 有降!

② 善拔因子法 $Var(\hat{\beta}(k)) = \frac{\delta^2 (X^T X)}{\delta^2 (X^T X + kI)^{-1} X^T X (X^T X + kI)^{-1}}$

$$= \delta^2 C(k)$$

$C(k)$ 的对角线元素 $C_{jj}(k)$ 为岭估计 善拔因子.

$k \uparrow C_{jj}(k) \downarrow$. 选择合适的 k 使所有 $C_{jj}(k) \leq CVF$ 考虑 k !

③ Horel-Kennard's / Mcdonald-Garneau's 公式 \rightarrow 使得 $||\hat{\beta}||^2 - ||\hat{\beta}(k)||^2 \approx \delta^2 \sum_{j=1}^p \lambda_j^{-1}$

$$k_{HK} = \frac{\delta^2}{\max_j \hat{\alpha}_j^2}$$

$\alpha = \sqrt{\beta} ???$ 这里要翻!

$$\text{选择 } k \text{ 使得 } ||\hat{\beta}(k)||^2 \approx ||\hat{\beta}||^2 - \delta^2 \sum_{j=1}^p \lambda_j^{-1} \quad [20]$$

主成分回归

主成分分析 + 回归分析

研究 y 与 $X = [x_1, x_2, \dots, x_p]^T$ 之间的关系

用 k 个自变量的
线性变换(主成分)

代替原本的 p 个自变量 ($k < p$)

如何找主成分? 如何利用主成分估计 β ? 主成分回归 \hat{y}_p 与 \hat{y} 什么关系?

自变量个数太多 \rightarrow 我们用较少的综合变量代替原本那么多的自变量
而且这几个综合变量还能尽可能 cover 车辆原本变量信息

$X = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix}$ p 维随机向量 $E(x) = \bar{M}$ $Var(x) = \Sigma$ 方差协方差阵

$$Z_1 = a_1^T x = a_{11} x_1 + a_{12} x_2 + \dots + a_{1p} x_p$$

$$Z_2 = a_2^T x = a_{21} x_1 + a_{22} x_2 + \dots + a_{2p} x_p$$

$$Z_p = a_p^T x = \dots$$

$$Var(Z_i) = a_i^T \Sigma a_i \quad Cov(Z_i, Z_j) = a_i^T \Sigma a_j$$

我们希望用 Z_i 替换

原本的 p 个变量

x_1, \dots, x_p

新变量尽可能多反映原来 p 个变量信息

我们如何度量信息? 用方差 $Var(Z_i)$

$Var(Z_i) = a_i^T \Sigma a_i$ 对 a_i 作出一些限制 $a_i^T a_i = 1$

若存在, 满足以上的 a_i , 使 $Var(Z_i) \max$ 则 Z_i 为第 1 主成分

... 进一步得第 2 主成分, 第 3 主成分, ...

有个需要 alert 的, 在第 1 主成分中体现的信息不能出现在第 2, 3, ... 主成分中

$$Cov(Z_2, Z_1) = 0 = a_2^T \Sigma a_1 = 0 \dots$$

$$X = \begin{bmatrix} x_1 \\ \vdots \\ x_p \end{bmatrix} \text{ 为了维 } \sim a_i = \begin{bmatrix} a_{1i} \\ \vdots \\ a_{pi} \end{bmatrix}$$

若 $a_i^T a_j = 0$

$Z_i = a_i^T x$ 是 x 的线性组合

① 且 $a_i^T a_i = 1$ ② $i > 1$ 时
 $a_i^T \Sigma a_j = 0$ ($i \neq j$)

这只是性质, 具体如何?

$$\text{若 } E(a) = 0 \quad Var(x) = \Sigma$$

$$\text{第 1 主成分求法} \quad a_1 = \begin{bmatrix} a_{11} \\ \vdots \\ a_{1p} \end{bmatrix}$$

$$a_1 = \arg \max_a a^T x$$

$$\text{s.t. } a^T a = 1$$

$$L(a) = \text{Var}(a^T x) - \lambda(a^T a - 1)$$

$$= a^T \Sigma a - \lambda(a^T a - 1)$$

$$\text{③ } Var(Z_i) = \max_a \downarrow a^T \Sigma a = 1$$

$$\text{满足 } a_i^T a_i = 1$$

$$a_i^T \Sigma a_j = 0, j = 1, \dots, i-1$$

则 $Z_i = a_i^T x$ 为 x 的第 i 个主成分

$$\begin{cases} \frac{\partial L}{\partial a} = 0 = \lambda(\sum_i a_i) \\ \frac{\partial L}{\partial \lambda} = 0 = a^T a - 1 \end{cases}$$

得 $|\sum_i a_i| = 0$ (由于 $a \neq 0$) \rightarrow 放弃第1主成分
之后的主成分方法也类似 等价于 $\sum_i a_i$ 的特征值和特征向量

Σ 的特征值为 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_P \geq 0$
特征 a_1, \dots, a_P 为 相应的 单位正交 特征向量

X 的第*i* 主成分为 $z_i = a_i^T x$ $i = 1, 2, \dots, P$

主成分总是优先选择较大的变量, 有时结果不合理
(为了解除量纲不同带来的不合理结果, 自变量要标准化)

$$E(x_i) = \mu_i \quad \text{Var}(x_i) = \sigma_i^2 \quad x_i^* = \frac{x_i - E(x_i)}{\sqrt{\text{Var}(x_i)}} = \frac{x_i - \mu_i}{\sigma_i}$$

x^* 的 Σ^* 就是原随机向量 x 的相关阵 $\text{corr}(x)$ \rightarrow 由此柱成分

由 $\text{corr}(x)$ 确定的主成分为

$$\Sigma^* = \begin{bmatrix} z_1^* \\ \vdots \\ z_P^* \end{bmatrix} \quad \text{Var}(z^*) = \Lambda^* = \text{diag}\{z_1^*, \dots, z_P^*\}$$

$$\sum_{i=1}^P z_i^* = P$$

之前讨论的问题中 Σ 未知, 要通过样本估计呢?

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1P} \\ x_{21} & x_{22} & \dots & x_{2P} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nP} \end{bmatrix} = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{bmatrix}$$

$$\Sigma \text{ 的估计: } S = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T$$

$$\text{样本相关阵 } R = (r_{KL})_{P \times P} \quad r_{KL} = \frac{s_{KL}}{\sqrt{s_{KK} s_{LL}}}$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n \bar{x}_i = \begin{bmatrix} \bar{x}_1 \\ \vdots \\ \bar{x}_P \end{bmatrix}$$

标准化后 X X^*

$$X^* = \begin{bmatrix} z_{11}^* & \dots & z_{1P}^* \\ \vdots & \ddots & \vdots \\ z_{n1}^* & \dots & z_{nP}^* \end{bmatrix}$$

$$z_{ij}^* = \frac{x_{ij} - \bar{x}_j}{\sqrt{L_{jj}}} \quad L_{jj} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$$

按列平均

$$\begin{bmatrix} \bar{x}_1 \\ \vdots \\ \bar{x}_P \end{bmatrix}$$

$$S_{KL} = \frac{1}{n-1} \sum_{i=1}^n (x_{ik} - \bar{x}_k)(x_{il} - \bar{x}_l)$$

$$\frac{1}{n-1} \sum_{i=1}^n (x_{ik} - \bar{x}_k)(x_{il} - \bar{x}_l)$$

$(X^*)^T X^*$ 可等价于 R .

以上都太有用感觉: | 写到了课件 P105
主成分回归我是真不懂, 所以笔记23页先空了, 回头再补吧!

(0.1)(0)

題目：某公司有 100 台機器，每台機器的故障率是 0.1，求 10 台機器同時故障的機率。

$$P(X = 10) = \frac{100!}{10!} \cdot (0.1)^{10} \cdot (0.9)^{90}$$

題目：某公司有 100 台機器，每台機器的故障率是 0.1，求 10 台機器同時故障的機率。

$$P(X = 10) = \frac{100!}{10!} \cdot (0.1)^{10} \cdot (0.9)^{90}$$

題目：某公司有 100 台機器，每台機器的故障率是 0.1，求 10 台機器同時故障的機率。

$$\frac{100!}{10!} \cdot (0.1)^{10} \cdot (0.9)^{90} = \frac{100 \cdot 99 \cdot 98 \cdot \dots \cdot 1}{10 \cdot 9 \cdot 8 \cdot \dots \cdot 1} \cdot (0.1)^{10} \cdot (0.9)^{90}$$

主成分

$$\frac{100!}{10!} \cdot (0.1)^{10} \cdot (0.9)^{90} = 100 \cdot 99 \cdot 98 \cdot \dots \cdot 1 \cdot (0.1)^{10} \cdot (0.9)^{90}$$



即 0.1 的 10 次方

$$\frac{100 \cdot 99 \cdot 98 \cdot \dots \cdot 1}{10 \cdot 9 \cdot 8 \cdot \dots \cdot 1} \cdot (0.1)^{10} \cdot (0.9)^{90}$$

X X 的總和

$$\frac{100 \cdot 99 \cdot 98 \cdot \dots \cdot 1}{10 \cdot 9 \cdot 8 \cdot \dots \cdot 1} \cdot (0.1)^{10} \cdot (0.9)^{90}$$

$$\frac{100 \cdot 99 \cdot 98 \cdot \dots \cdot 1}{10 \cdot 9 \cdot 8 \cdot \dots \cdot 1} \cdot (0.1)^{10} \cdot (0.9)^{90}$$

X X 的總和

題目：某公司有 100 台機器，每台機器的故障率是 0.1，求 10 台機器同時故障的機率。

聚类

人类对个体特征进行归纳，相似个体归为一类，以类的特征代替个体信息。
 聚类：分别从属特征总体的个体 / 没别异同个体
 ↳ 核心问题：如何定义个体间相似性？如何确定类别数？如何选个体特征？

无序签表对属集 无监督学习

如何评价聚类的结果？

$$\left\{ \begin{array}{l} \text{样本 } x_1, \dots, x_n \quad x_i = \begin{bmatrix} x_{i1} \\ \vdots \\ x_{iP} \end{bmatrix} \\ \text{ } \quad x = \begin{bmatrix} x_1 & x_{12} & \dots & x_{1P} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nP} \end{bmatrix} \end{array} \right.$$

$$\text{曼哈顿} \sum_{i=1}^P |x_{1i} - x_{2i}|$$

$$\text{切比雪夫} \max_i |x_{1i} - x_{2i}|$$

$$\text{兰氏} \frac{\sum_{i=1}^P |x_{1i} - x_{2i}|}{\max_i |x_{1i}| + |x_{2i}|}$$

$$\text{余弦相似度} \cos \theta = \frac{a^T b}{\|a\| \|b\|}$$

- 基本距离

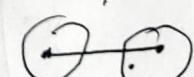
点间距离 $s_j = s_j(x_{kj}, x_{lj})$ x_k 和 x_l 在第 j 个特征之间的相似性

相似度定义 两个观测值 x_k 和 x_l 间相似度

$$s(x_k, x_l) = \frac{\sum_i s_i(x_{ki}, x_{li}) \cdot w_i}{\sum_i s(x_{ki}, x_{li}) w_i}$$

$$s(x_{ki}, x_{li}) = \begin{cases} 0 & x_{ki} \text{ 或 } x_{li} \text{ 中存在缺失观测} \\ 1 & \text{其他} \end{cases} \quad w_i \text{ 表权重}$$

类间距离 (类联结则) 两类中距离最短 / 最长 / 重心



LW公计则

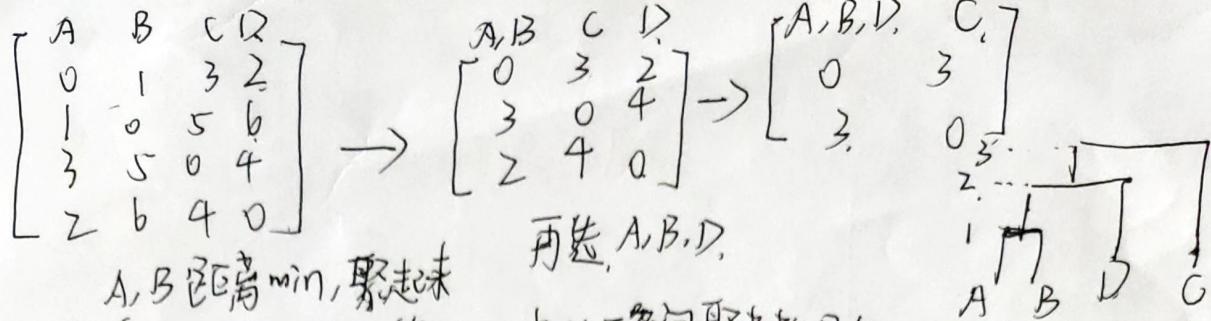
层次聚类

自下而上 每个样本各自分到一类，之后将类间距离最近的两类联结起来

自上而下 所有样本归入一个大类，之后类中距离最远的样本记为两个新类，基于它们将被进行聚类的点逐一与这两个中心点比较距离，并放入。之后在更小的类中执行相同操作。

建一个新的类
反复，直到所有样本聚合到一个类中

自下而上-层次聚类，4点



A, B 距离 min, 聚起来

K均值 kmeans 计算快 事先确定聚类数目 K

将 n 个样本划入 K 类中 $C_i \cap C_j = \emptyset$ $\bigcup_{i=1}^K C_i = X$

要找一个最优划分, 使类内距离足够小, 类间距离足够大.

以平方欧氏距离最通用. 损失函数 $W(C_1 \dots C_K)$

$$\arg \min W(C_1, C_2, \dots, C_K) = \sum_{i=1}^K \sum_{j \in C_i} \|x_j - m_i\|^2.$$

其中 m_i 为第 i 类的

NP-hard 问题, 迭代法解

每次迭代 2 个步骤: ① 确定 k 个类的重心 m_i

将样本逐一分配到其最近的中心所属类中, 得聚类结果

② 更新每类的样本均值(重心) 重复①②直至 W 变化不大 (收敛)

各类数据集非凸, 又倒立纹 聚类结果不唯一也可认为收敛

混合高斯模型 GMM 核心: 分布的假定

假定第 i 个样本 x_i 来自于第 j 类正态分布 $N_p(M_j, \Sigma_j)$

$$f(x_i) = (2\pi)^{-\frac{p}{2}} |\Sigma_j|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - M_j)^T \Sigma_j^{-1} (x_i - M_j) \right\}$$

超参数还是 K , 聚类数目. $\delta_{ij} = \begin{cases} 1 & x_i \sim N_p(M_j, \Sigma_j) \\ 0 & x_i \not\sim N_p(M_j, \Sigma_j) \end{cases}$

$\delta_i = \begin{bmatrix} \delta_{i1} \\ \vdots \\ \delta_{iK} \end{bmatrix}$ 独立同分布

$$f(\delta_i) = \prod_{j=1}^K (\pi_j)^{\delta_{ij}} \quad \pi_j = P(\delta_{ij} = 1)$$

$$f(x_i | \delta_i) = \prod_{j=1}^K \left((2\pi)^{-\frac{p}{2}} |\Sigma_j|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - M_j)^T \Sigma_j^{-1} (x_i - M_j) \right\} \right)$$

$$\text{联合密度函数} \prod_{i=1}^n f(x_i, \delta_i) = \prod_{i=1}^n f(\delta_i) \cdot f(x_i | \delta_i)$$

$$= \prod_{i=1}^n \prod_{j=1}^K \left((\pi_j) \cdot (2\pi)^{-\frac{p}{2}} |\Sigma_j|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - M_j)^T \Sigma_j^{-1} (x_i - M_j) \right\} \right)$$

要求未知参数 $(\pi_1 \dots \pi_K, M_1 \dots M_K, \Sigma_1 \dots \Sigma_K)$

现在只有样本 $x_1 \dots x_n$ 无法观测 $s_1 \dots s_n$ 无法直接估计未知参数

x_1 的密度函数

$$f(x_1) = f(x_1 | s_1) f(s_1) = \sum_{j=1}^K \pi_j (2\pi)^{-\frac{1}{2}} |\sum_j|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_1 - \mu_j)^T \sum_j^{-1} (x_1 - \mu_j) \right\}$$

高斯混合模型 \rightarrow EM 算法未解 证明 skip 了，太长了

对了 24 那个貝叶斯密度函数 \rightarrow y, 再…… 看课件吧！

DBSCAN 基于密度的聚类算法 要判断两个样本属于同类，那么在两个样本附近，能找两个属于同一类别的样本

给定 $\varepsilon > 0$ 和最少样本个数 minPts

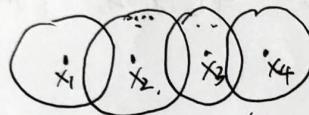
若 $N_\varepsilon(k) = \{x_L \in X \mid d(x_k, x_L) \leq \varepsilon\} \geq \text{minPts}$ 称 x_k 为核心点

若 $|N_\varepsilon(k)| \geq \text{minPts}$, x_L 可以从 x_k 直接密度可达

若 $x_L \in N_\varepsilon(k)$ 且 $|N_\varepsilon(k)| \geq \text{minPts}$, x_L 从 x_k 密度连接

$\exists x_i$: x_i 使得 x_k 和 x_L 均从 x_i 密度可达，则称 x_k 和 x_L 密度连接

密度可达: 一堆点 $x_k \dots x_n$ 使得 x_{i+1} 从 x_i 直接密度可达
 \rightarrow x_n 从 x_1 密度可达



$[x_4 \text{ 由 } x_2]$
密度可达
我这个图这样

密度连接 以
 x_i x_j 中间找一点 x_u
使 x_i 和 x_j 均可以 x_u
密度可达

x_k 都是
核心点

x_u, x_L 不是

DBSCAN algorithm:

$X = (x_1 \dots x_n)^T$, ε , minPts 给定

初始化: 类别序号 $k=0$

标记每个样本为未访问过 $V[i] = 0$, $i = 0, 1 \dots n$

从 X 中随机选一个未访问过的样本 x_i

~~if x_i 未访问 x_i 访问过 $V[i] = 1$~~

计算 x_i 的 ε 邻域 $N_\varepsilon(i)$

if x_i 不是核心点; x_i 是噪声

else {

$k++$; $G(i)$ 表示 x_i 所有密度可达的点

for $x_j \in G(i)$ {
if (x_j 未访问) $V[i, j] = 1$. 将 x_j 归入 k 类

}

3

聚类的评价 [外部聚类有效性] 区别是否用外部的信息
内部 ~

n 个样本 $x_1 \dots x_n$ 分类结果 $C_1 \dots C_K$
假设真实的标签是 $P_1 \dots P_K$

$$P_{ij} = \frac{n_{ij}}{n} \quad P_{i \cdot} = P_i = \frac{n_{i \cdot}}{n}$$

$$\text{熵 } E = - \sum P_i \left(\sum \frac{P_{ij}}{P_i} \log \frac{P_{ij}}{P_i} \right)$$

$$\text{纯度 } P = \sum_i P_i \left(\max_j \frac{P_{ij}}{P_i} \right)$$

		可能矩阵:	
		$P_1 \dots P_K$	$n_{i \cdot}$
C_i	$n_{i1} \dots n_{iK}$	$n_{i \cdot}$	
	$n_{i1} \dots n_{iK}$	$n_{i \cdot}$	

内部聚类有效性: ① 紧密度 (同一类内不同个体之间紧密关联的度量)
低差异 (\Rightarrow) 紧密度好, 很多紧密度定义依赖于距离

② 区分度 (不同类间区别程度的度量)

两簇中心的距离 ... 密度也行,

$$\text{均方差, RMSSTD} = \left(\frac{\sum_{j=1}^K \sum_{i \in C_j} \|x_i - m_j\|^2}{P \sum_{j=1}^K (m_j - 1)} \right)^{\frac{1}{2}} \quad \text{轮廓法, CH 指数略!}$$

$$\text{又方 } RS = 1 - \frac{\sum_{j=1}^K \sum_{i \in C_j} \|x_i - \bar{x}\|^2}{\sum_{i=1}^n \|x_i - \bar{x}\|^2}$$

① 差分析那里的先跳过, 回头看
 $I - H$ 置等阵, $(I - H)^2 = I - H$ $\text{rank}(I - H) = \text{Tr}(I - H) = \text{Tr}(I) - \text{Tr}(H) = n - (p+1) = n - p - 1$

② 多元线性回归 model 中, y_i 的回归值 $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_p x_p$
 X 为满秩矩阵, 证明 $\sum_{i=1}^n (y_i - \hat{y}_i) = 0$ 因为 $H = H^T$

$$y - \hat{y} = y - x\hat{\beta} = y - Hy = (I - H)y \quad \uparrow$$

$$\text{而 } I^T(y - \hat{y}) = I^T(I - H)y = (I^T - I^T H)y = (I^T - H\vec{1})^T y$$

然后 $H\vec{1} = X(X^T X)^{-1} X^T \vec{1}$ X 的第 1 列 - 堆 1 ($\vec{1}$) 故 $X^T \vec{1} = \vec{1}$

$$H\vec{1} = X(X^T X)^{-1} X^T \vec{1} = X(X^T X)^{-1} X^T X\vec{\alpha} = X\vec{\alpha} = \vec{1} \quad X \cdot \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \vec{1}$$

$$\text{故 } I^T(y - \hat{y}) = (I^T - (H\vec{1})^T) y \quad \text{全消了!} \quad (\text{取 } \vec{\alpha} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix})$$

$$= (I^T - I^T) y = \vec{0} \quad \text{原式得证.}$$

③ $y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon$ \rightarrow 得最小二乘估计为 $\hat{\beta}$

若我们对 y_1, y_2, \dots, y_n 中心化, 对 $x_{1j}, x_{2j}, \dots, x_{nj}$ ($j = 1, 2, \dots, p$) \rightarrow 标准化

得最小二乘估计 $\tilde{\beta}$ $\hat{\beta}$ 和 $\tilde{\beta}$ 有何关系? $E(\tilde{\beta}) = ?$ $\text{Var}(\tilde{\beta}) = ?$

原模型 $y = x\beta + \varepsilon$ $y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$ $x = \begin{bmatrix} \vec{1}_n & x_0 \end{bmatrix}$ $x_0 = \begin{bmatrix} \vec{x}_1 & \dots & \vec{x}_p \end{bmatrix}$

$$\hat{\beta} = (X^T X)^{-1} X^T y = \begin{bmatrix} -n & \vec{1}_n^T x_0 \\ \vec{1}_n \vec{1}_n^T & x_0^T x_0 \end{bmatrix}^{-1} \begin{bmatrix} \vec{1}_n^T \\ x_0 \end{bmatrix} y$$

$$\text{中心化 } y \text{ 得 } \vec{y}^* = y - H_{1n} y = (I - H_{1n}) y \quad H_{1n} = \vec{1}_n (\vec{1}_n^T \vec{1}_n)^{-1} \vec{1}_n^T$$

$$\text{标准化 } x_{1j}, x_{2j}, \dots, x_{nj} \text{ 得 } x_S = x_C L = (I - H_{1n}) x_0 L$$

$$\text{标准化 } y^* = \frac{1}{\sqrt{L_{yy}}} y^* = \frac{1}{\sqrt{L_{yy}}} (I - H_{1n}) y \quad L = \text{diag}\left\{\frac{1}{\sqrt{L_{11}}}, \dots, \frac{1}{\sqrt{L_{pp}}}\right\}$$

$$L_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$\hat{\beta}_{S, \text{ slope}} = \tilde{\beta} = \begin{bmatrix} -n & \vec{1}_n^T x_S \\ x_S^T \vec{1}_n & x_S^T x_S \end{bmatrix}^{-1} \begin{bmatrix} \vec{1}_n^T \\ x_S^T \end{bmatrix} y^*$$

$$= \begin{bmatrix} -\frac{1}{n} \vec{1}_n^T + \frac{1}{n^2} \vec{1}_n^T x_S A_1 x_S^T \vec{1}_n \vec{1}_n^T - \frac{1}{n} \vec{1}_n^T x_S A_1 x_S^T \\ -\frac{1}{n} A_1 x_S^T \vec{1}_n \vec{1}_n^T + A_1 x_S^T \end{bmatrix} y^*$$

$$A_1 = \left[x_S^T x_S - \frac{1}{n} x_S^T \vec{1}_n \vec{1}_n^T x_S \right]^{-1}$$

$$\text{其中 } \mathbf{I}_n^T \mathbf{X}_S = \mathbf{I}_n^T \mathbf{X}_S \cdot \mathbf{L} = \mathbf{I}_n^T (\mathbf{I} - \mathbf{H}_{\mathbf{I}_n}) \mathbf{X}_S \mathbf{L} = \mathbf{0}_{1 \times n} \quad \mathbf{I}_n^T \mathbf{H}_{\mathbf{I}_n} = \mathbf{I}_n^T \mathbf{I}_n \cdot (\mathbf{I}_n^T \mathbf{I}_n)^{-1} \mathbf{I}_n^T = \mathbf{I}_n^T$$

$$\text{故 } \frac{1}{n} \mathbf{I}_n^T \mathbf{X}_S \mathbf{A}_1 \mathbf{X}_S^T = \mathbf{0}_{1 \times n} \quad (\mathbf{X}_S^T \mathbf{I}_n = \mathbf{0}_{n \times 1})$$

$$-\frac{1}{n} \mathbf{I}_n^T \mathbf{X}_S \mathbf{A}_1 \mathbf{X}_S^T = \mathbf{0}_{1 \times n}$$

$$\text{故 } \tilde{\beta} = \begin{bmatrix} \frac{1}{n} \mathbf{I}_n^T \\ \mathbf{A}_1 \mathbf{X}_S^T \end{bmatrix} \quad y^* = \begin{bmatrix} \frac{1}{n} \mathbf{I}_n^T \\ \mathbf{A}_1 \mathbf{X}_S^T \end{bmatrix} (\mathbf{I} - \mathbf{H}_{\mathbf{I}_n}) \mathbf{y} = \begin{bmatrix} 0 \\ \mathbf{A}_1 \mathbf{X}_S^T (\mathbf{I} - \mathbf{H}_{\mathbf{I}_n}) \mathbf{y} \end{bmatrix}$$

$$\text{同理, } \mathbf{A}_1 = [\mathbf{X}_S^T \mathbf{X}_S - \frac{1}{n} \mathbf{X}_S^T \mathbf{I}_n \mathbf{I}_n^T \mathbf{X}_S]^{-1} = [\mathbf{X}_S^T \mathbf{X}_S]^{-1}$$

$$\text{故 } \mathbf{A}_1 \mathbf{X}_S^T (\mathbf{I} - \mathbf{H}_{\mathbf{I}_n}) \mathbf{y} = (\mathbf{X}_S^T \mathbf{X}_S)^{-1} \mathbf{X}_S^T (\mathbf{I} - \mathbf{H}_{\mathbf{I}_n}) \mathbf{y} = (\mathbf{X}_S^T \mathbf{X}_S)^{-1} \mathbf{X}_S^T \mathbf{y}^*$$

统一转化为中心化
遵循关系

正常来说, 全面中心化之后解为

$$\star (\mathbf{X}_S^T \mathbf{X}_S)^{-1} \mathbf{X}_S^T \mathbf{y}^*$$

$$\hat{\beta}_{slope} = \frac{1}{\sqrt{Lyy}} L^{-1} \hat{\beta}_{slope}$$

$$\text{对比可知, 题中所求 } \hat{\beta}_{new, slope} = \mathbf{A}_1 \mathbf{X}_S^T (\mathbf{I} - \mathbf{H}_{\mathbf{I}_n}) \mathbf{y} = \sqrt{Lyy} \cdot (\mathbf{X}_S^T \mathbf{X}_S)^{-1} \mathbf{X}_S^T \mathbf{y}^*$$

$$= \sqrt{Lyy} \cdot \hat{\beta}_{slope} = L^{-1} \hat{\beta}_{slope}$$

$$\tilde{\beta} = \begin{bmatrix} 0 \\ L^{-1} \hat{\beta}_{slope} \end{bmatrix} \quad \hat{\beta} = \begin{bmatrix} \hat{\beta}_{intercept} \\ \hat{\beta}_{slope} \end{bmatrix} \quad \tilde{\beta} = \begin{bmatrix} 0_{1 \times 1} & 0_{1 \times p} \\ 0_{p \times 1} & L^{-1} \end{bmatrix} \cdot \hat{\beta}$$

$$E(\hat{\beta}) = \beta \quad T = \begin{bmatrix} 0 & 0 \\ 0 & L^{-1} \end{bmatrix}$$

这便是关系!

$$E(\tilde{\beta}) = T\beta \quad \text{Var}(\tilde{\beta}) = \delta^2 (\mathbf{X}^T \mathbf{X}) \quad \text{Var}(\tilde{\beta}) = \delta^2 T (\mathbf{X}^T \mathbf{X}) T^T$$

④. 证明: 单因子方差分析模型可看作一种多元线性回归 model 具体证明就不写呢

⑤. \mathbf{X}_S 表示标准化后的特征 $\mathbf{X}_S = (x_1, x_2 \dots x_p)$ \mathbf{X}_S 相关系数阵为 $\mathbf{X}_S^T \mathbf{X}_S$

逆矩阵为 $(\mathbf{X}_S^T \mathbf{X}_S)^{-1} = C = \{C_{ij}\}$ 我们将 x_j 作因变量, 而将剩余特征作

自变量, 建立多元线性回归 model: $x_j = \alpha_1^j x_1 + \dots + \alpha_{j-1}^j x_{j-1} + \alpha_{j+1}^j x_{j+1} + \dots + \alpha_p^j x_p$

该模型决定系数 R_j^2 证明 $\star C_{ij} = \frac{1}{1 - R_j^2}$

$$SS_R^j = \sum_{i=1}^n (x_{ji} - \bar{x}_j)^2 \quad \text{数据被标准化则 } \mathbf{I}^T \mathbf{X}_i = 0 \quad \mathbf{X}_i^T \mathbf{x}_i = 0 \quad (i=1, 2 \dots p)$$

$$= \sum_{i=1}^n \hat{x}_{ji}^2 = \hat{\mathbf{x}}_j^T \hat{\mathbf{x}}_j \quad \text{其中 } \hat{\mathbf{x}}_j = \mathbf{X}_S^T \hat{\beta} \quad = \mathbf{X}_S^T (\mathbf{X}_{Sj}^T \mathbf{X}_{Sj})^{-1} \mathbf{X}_{Sj}^T \mathbf{x}_j$$

$$\text{故 } SS_R^j = \hat{\mathbf{x}}_j^T \hat{\mathbf{x}}_j = \dots \quad \leftarrow \quad \text{L} \rightarrow \text{因为这里 } x_j \text{ 为因变量.}$$

$$= \hat{\mathbf{x}}_j^T \cdot \mathbf{X}_{Sj} (\mathbf{X}_{Sj}^T \mathbf{X}_{Sj})^{-1} \mathbf{X}_{Sj}^T \mathbf{x}_j \quad \mathbf{X}_{Sj} = (x_1, x_2 \dots x_{j-1}, x_{j+1} \dots x_p)$$

$$SS_T^j = \sum_{k=1}^n (x_{jk} - \bar{x}_j)^2 = \sum_{k=1}^n x_{jk}^2 = 1$$

$$\text{故 } R_j^2 = \frac{SS_R^j}{SS_T^j} = x_j^T x_{sj} (x_{sj}^T x_{sj})^{-1} x_{sj}^T x_j$$

$$x_s = [x_j \ x_{sj}] A_j \quad A_j = \begin{bmatrix} 1 & \dots & 0 & \dots \end{bmatrix} \quad A_j^{-1} = A_j^T$$

把IP的第j列换到第1列
第1至j-1列都往后推一列

$$x_s A_j = [x_j \ x_{sj}]$$

$$x_s = [x_j \ x_{sj}] A_j^T$$

$$C = (x_s^T x_s)^{-1} = \left[A_j \begin{bmatrix} x_j^T \\ x_{sj}^T \end{bmatrix} [x_j \ x_{sj}] A_j^T \right]^{-1} = A_j \begin{bmatrix} 1 & x_j^T x_{sj} \\ x_{sj}^T x_j & x_{sj}^T x_{sj} \end{bmatrix}^{-1} A_j^T$$

A_j 左乘意味着... A_j^T 右乘, 意味着...

$$A_j \begin{bmatrix} \quad \end{bmatrix}^{-1} A_j^T \rightarrow \text{代表着的是取矩阵第一行第一个元素!}$$

$$C_{ij} = \frac{1}{1 - x_j^T x_{sj} (x_{sj}^T x_{sj})^{-1} x_j^T x_j}$$

但我觉得这个方法 too stupid. 原书得证

⑥

$$\hat{\beta} = (x^T x)^{-1} x^T y \quad \text{MSE}(\hat{\beta}) = E(\hat{\beta}^T - \beta^T)(\hat{\beta} - \beta) = ?$$

$$\text{MSE}(\hat{\beta}) = E((\hat{\beta} - \beta)^T (\hat{\beta} - \beta)) = E((\hat{\beta} - E(\hat{\beta}))^T (\hat{\beta} - E(\hat{\beta})))$$

$$\hookrightarrow E(\hat{\beta}) = \beta$$

$$\underline{= \text{Tr}(\text{cov}(\hat{\beta})) = \text{Tr}(\hat{\sigma}^2 (x^T x)^{-1}) = \hat{\sigma}^2 \text{Tr}((x^T x)^{-1})}$$

统计方法实验内容 review

$$\bar{y}_{i.} \sim N(M_i, \frac{\hat{\sigma}^2}{m})$$

$$\frac{\bar{y}_{i.} - M_i}{\sqrt{\hat{\sigma}^2 \frac{1}{m}}} = \frac{\bar{y}_{i.} - M_i}{\hat{\sigma} \sqrt{\frac{1}{m}}} \sim N(0, 1)$$

$$\frac{SSE}{\hat{\sigma}^2} \sim \chi^2(n-a)$$

$$\text{t} \propto \frac{\bar{y}_{i.} - M_i}{\hat{\sigma} \sqrt{\frac{1}{m}}} \cdot \frac{1}{\sqrt{\frac{SSE}{\hat{\sigma}^2(n-a)}}} = \frac{\bar{y}_{i.} - M_i}{\hat{\sigma} \sqrt{\frac{SSE}{\hat{\sigma}^2(n-a)}}} \sim t(n-a)$$

这也是 Tukey
方法的
核心

jqw 上课主要讲统计学习方法(李航) 第一篇: 监督学习 2023.12.
所以我复习主要用这个展开

用我的 Note 结构是这样的: 先放一堆例题, 再自己亲自去存那本 B 对应部分并留 Note, 我结合其中的一些过于精简的部分加一些内容, 数据

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	3	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
Y	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1

由此来确定一个朴素贝叶斯分类器, 并确定 $X = (2, S)^T$ 的类标记 Y
取值集合 $A_1 = \{1, 2, 3\}$ $A_2 = \{S, M, L\}$ $Y \in C = \{-1, 1\}$ 为类标记,
我的理解, 要求 $P(X=x, Y=Y_k) \rightarrow$ 先求 $P(Y=Y_k)$ 再求 $P(X=x | Y=Y_k)$
然后再乘一下, 找 $P(X=x, Y=Y_k) \max$ 的 Y_k 为分类
(先不放拉普拉斯平滑)

$$P(Y=-1) = \frac{2}{5} \quad P(Y=1) = \frac{3}{5}$$

$$P(X^{(1)}=1 | Y=-1) = \frac{1}{4} \quad P(X^{(1)}=1 | Y=1) = \frac{2}{9}$$

$$P(X^{(2)}=2 | Y=-1) = \frac{1}{3} \quad P(X^{(2)}=2 | Y=1) = \frac{1}{3}$$

$$P(X^{(1)}=3 | Y=-1) = \frac{1}{6} \quad P(X^{(1)}=3 | Y=1) = \frac{4}{9}$$

$$P(X^{(2)}=S | Y=-1) = \frac{1}{2} \quad P(X^{(2)}=S | Y=1) = \frac{1}{9}$$

$$P(X^{(2)}=M | Y=-1) = \frac{1}{3} \quad P(X^{(2)}=M | Y=1) = \frac{4}{9}$$

$$P(X^{(2)}=L | Y=-1) = \frac{1}{6} \quad P(X^{(2)}=L | Y=1) = \frac{4}{9}$$

$$\text{然后求 } P(X=x, Y=1) = P(X=x | Y=1) \cdot P(Y=1)$$

$$= P(Y=1) \cdot P(X^{(1)}=2 | Y=1) P(X^{(2)}=S | Y=1)$$

$$P(X=x, Y=-1) = P(X=x | Y=-1) \cdot P(Y=-1) = P(Y=-1) \cdot P(X^{(1)}=2 | Y=-1)$$

$$P(X^{(2)}=S | Y=-1)$$

$$\text{后面那个更大, 故 } Y=-1 \text{ 这便是分类结果} = \frac{1}{15}$$

再用拉普拉斯平滑

$\lambda = 1$

二分类问题

$K = 2$

$$P(Y=1) = \frac{9+1}{15+2 \times 1} = \frac{9}{17} \quad P(Y=-1) = \frac{6+1}{15+2 \times 1} = \frac{7}{17}$$

$$P(X^{(1)}=1|Y=1) = \frac{2+1}{1+3} = \frac{3}{4}$$

△拉普拉斯平滑要加这个
主语是 $X^{(1)}$!
 $Y=1$ 的数量

$X^{(1)}$ 是二分类
的变量

△拉普拉斯平滑要加这个

$X^{(1)}$ 是3分类

分子一直都+1的尾

终于搞明白这个了，这之后的过程类似。

我先大致写下SVM的基本理论，再去看看“核技巧”。

No. 2023/12/23
Date.

训练集 $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ $y_i = \begin{cases} +1 & \text{正例} \\ -1 & \text{负例} \end{cases}$

SVM要解决：通过间隔最大(或等价形式)求得分离超平面 $w \cdot x + b = 0$

相应的分类决策函数 $f(x) = \text{sign}(wx + b)$

超平面关于 (x_i, y_i) 的函数间隔 $r_i = y_i(w \cdot x_i + b)$

关于整个训练集的函数间隔 $r = \min_{i=1 \dots n} r_i$

几何间隔 \rightarrow 分别对应乘 $\frac{1}{\|w\|}$ 就行 \rightarrow 取 $\|w\| = 1$ 约束

最大间隔分离超平面 $\max r$ (对偶)

$$\begin{array}{l} \text{s.t. } y_i \left(\frac{w \cdot x_i}{\|w\|} + \frac{b}{\|w\|} \right) \geq 1 \quad i=1, 2 \dots n \end{array}$$

线性可分支持向量机学习的最优化问题：

$$\begin{array}{l} \min_{w, b} \frac{1}{2} \|w\|^2 \rightarrow \text{得最优解 } w^*, b^* \end{array}$$

$$\text{s.t. } y_i(w \cdot x_i + b) \geq 1 \quad i=1, 2 \dots n$$

凸优化问题复习 $\min f(w)$

$$\text{s.t. } g_i(w) \leq 0 \quad i=1, 2 \dots k \quad L(w, \alpha, \beta)$$

$$h_i(w) = 0 \quad i=1, 2 \dots L \quad = f(w) + \sum_{i=1}^k g_i(w) \alpha_i$$

$$\text{其中 } \alpha_i \geq 0 \quad (i=1 \dots k) \quad + \sum_{i=1}^L h_i(w) \beta_i$$

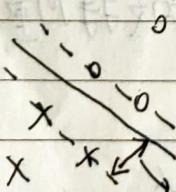
最大间隔分离超平面唯一

线性可分时

训练集的样本点

与分离超平面距离最近的

称为支持向量 (即 $y_i(w \cdot x_i + b) - 1 = 0$)



例题. 正例点 $(3, 3), (4, 3)$

负例点 $(1, 1)$ 求分离超平面?

$$\min \frac{1}{2} (w_1^2 + w_2^2)$$

$$\text{s.t. } 3w_1 + 3w_2 + b \geq 1$$

$$4w_1 + 3w_2 + b \geq 1$$

$$-w_1 - w_2 - b \geq 1$$

$$\text{得 } w_1 = \frac{1}{2}, w_2 = -\frac{1}{2}, b = 2$$

(背面有对偶算法)

拉-乘子.

$$L(w, b) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i y_i (w^T x_i + b) + \sum_{i=1}^n \alpha_i$$

$$\min \frac{1}{2} \|w\|^2$$

对偶问题 \rightarrow 极大极小问题:

$$\begin{cases} \text{s.t. } y_i (w^T x_i + b) \geq 1 \\ -y_i (w^T x_i + b) \leq -1 \end{cases}$$

$$\max_{w, b} \min_{\alpha} L(w, b, \alpha)$$

$$1. \min_{w, b} L(w, b, \alpha) = ?$$

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^n \alpha_i y_i x_i \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\nabla_b L(w, b, \alpha) = -\sum_{i=1}^n \alpha_i y_i = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

再代入 $L(w, b, \alpha)$ (消去 w, b) 得 $\min_{w, b} L(w, b, \alpha)$

$$= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \alpha_i$$

两首点乘.

$$2. \max_{\alpha} (\dots)$$

$$\max_{\alpha} \left[-\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^n \alpha_i \right]$$

$$\begin{cases} \text{s.t. } \sum_{i=1}^n \alpha_i y_i = 0 \\ \alpha_i \geq 0 \quad i=1, \dots, n. \end{cases} \quad \begin{matrix} \downarrow \text{再换为 min} \\ \text{即} \end{matrix}$$

这个可得 α^* (对偶问题最优解)这个是任意
原问题最优解 $w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$ \rightarrow 选定要

$$\text{这个 } \alpha_j^* > 0 \quad b^* = y_j - \sum_{i=1}^n \alpha_i^* y_i (x_i \cdot x_j) \quad \alpha_i^* > 0$$

支持向量. 训练集中对于 $\alpha_i^* > 0$ 的 (x_i, y_i) 即为支持向量.

$$\text{例. 正例点 } x_1 = (3, 3)^T, x_2 = (4, 3)^T, x_3 = (1, 1)^T$$

$$\text{对偶形式: } \min_{\alpha} \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^3 \alpha_i$$

$$= \min_{\alpha} 9\alpha_1^2 + \frac{25}{2}\alpha_2^2 + \alpha_3^2 + 21\alpha_1\alpha_2 - 6\alpha_1\alpha_3 - 7\alpha_2\alpha_3$$

$$\text{s.t. } \alpha_1 + \alpha_2 - \alpha_3 = 0$$

$$\alpha_i \geq 0 \quad i=1, 2, 3$$

$$\alpha_3 = \alpha_1 + \alpha_2 \text{ 代入式中 } S(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$

对 α_1, α_2 求偏导，令其为 0，得 $\begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = \begin{bmatrix} -\frac{3}{2} \\ -1 \end{bmatrix}$ 但这不行

$$\alpha_1 = 0, S_{\min} = -\frac{2}{13}, \alpha_2 = 0, S_{\min} = -\frac{1}{4}$$

故 $\alpha_1 = \frac{1}{4}, \alpha_2 = 0, \alpha_3 = \frac{1}{4}$ 代入 \rightarrow 故 x_1 和 x_3 为支持向量 (大于 0)

$$W^* = \sum_{i=1}^n \alpha_i^* y_i x_i = \frac{1}{4} \cdot 1 \begin{bmatrix} 3 \\ 3 \end{bmatrix} + 0 \cdot 1 \begin{bmatrix} 4 \\ 3 \end{bmatrix} + \frac{1}{4} (-1) \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

$$= \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \end{bmatrix} \quad W_1^* = \frac{1}{2} = W_2^*$$

$$\text{比如选 } \alpha_1^* = \frac{1}{4}, b^* = 1 - \sum_{i=1}^n \alpha_i^* y_i (x_i \cdot x_1)$$

$$= 1 - \left(\frac{1}{4} \cdot 18 + 0 + \frac{1}{4} \cdot (-1) \cdot 6 \right) = -2$$

$$\text{分离超平面 } \frac{1}{2} x^{(1)} + \frac{1}{2} x^{(2)} - 2 = 0$$

$$\text{分高决策函数 } f(x) = \text{sign}\left(\frac{1}{2} x^{(1)} + \frac{1}{2} x^{(2)} - 2\right)$$

每期末 正类 (+1, +1, 1), (2, 2), (2, 0) 负类 (0, 0) (1, 0) (0, 1)

用对偶方法来求解?

$$\text{对偶问题: } \min \frac{1}{2} \sum_{i=1}^6 \sum_{j=1}^6 \alpha_i \alpha_j \cdot y_i y_j (x_i \cdot x_j) - \sum_{i=1}^6 \alpha_i \frac{1}{2} B_i \left(\frac{1}{2} \right)$$

$$\text{s.t. } \alpha_1 + \alpha_2 + \alpha_3 - \alpha_4 - \alpha_5 - \alpha_6 = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, 6$$

$$\text{即 } \begin{aligned} \min \alpha_1^2 + 4\alpha_2^2 + 2\alpha_3^2 + \frac{1}{2}\alpha_4^2 + \frac{1}{2}\alpha_5^2 + 4\alpha_1\alpha_2 + 2\alpha_1\alpha_3 \\ + 4\alpha_2\alpha_3 - \alpha_1\alpha_5 - \alpha_1\alpha_6 - 2\alpha_2\alpha_5 - 2\alpha_2\alpha_6 - 2\alpha_3\alpha_5 - \sum_{i=1}^6 \alpha_i \end{aligned}$$

$$\text{硬导, 对 } \alpha_1: 2\alpha_1 + 4\alpha_2 + 2\alpha_3 - \alpha_6 = 0 - 1 = 0$$

$$\text{对 } \alpha_2: 8\alpha_2 + 4\alpha_1 + 4\alpha_3 - 2\alpha_5 - 2\alpha_6 - 1 = 0$$

... 9 对 反正就这算, 运算量大!

因为 w, b 在给定数据集时一定一模一样, 你笨办法先搞个

答案

列一堆式子
写答案就行

$$+1: (1,1) (2,2) (2,0) -1: (0,0) (1,0) (0,1)$$

$$\text{先用法来做} \min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} (w_1^2 + w_2^2)$$

$$\text{s.t. } w_1 + w_2 + b \geq 1 \quad b \leq -1$$

$$2w_1 + 2w_2 + b \geq 1 \quad b + w_1 \leq -1$$

$$w_1 + b \geq 1 \quad w_2 + b \leq -1$$

$$\text{这个怎样搞? } \begin{cases} w_1 + w_2 + b \geq 1 \\ 2w_1 + b \geq 1 \end{cases} \text{ 可想到 } w_1 = w_2 \\ \min w_1^2$$

$$\begin{cases} -2w_1 + b \geq 1 \\ 4w_1 + b \geq 1 \\ b \leq -1 \\ b + w_1 \leq -1 \end{cases} \Rightarrow \begin{cases} w_1 \geq 2 \\ b \leq -1 \\ b \text{ 必须要为 } -3 \end{cases} \text{ 由 } \dots \text{ 得 } \dots$$

$$(s^{(1)}x_1 + b)x_1 + (s^{(2)}x_2 + b)x_2 + \dots + (s^{(n)}x_n + b)x_n$$

$$(1,0) (0,1) (0,0) \text{ 类似 } (0,1) (s^{(1)} (1,0) + \dots)$$

$$0 = \sum_{i=1}^n s^{(i)} x_i + b$$

$$b = -\sum_{i=1}^n s^{(i)} x_i$$

$$0 = \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \dots$$

$$0 = 1 - 0 - \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \dots$$

$$0 = 1 - \sum_{i=1}^n s^{(i)} x_i - \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \dots$$

$$0 = 1 - \sum_{i=1}^n s^{(i)} x_i - \sum_{i=1}^n s^{(i)} x_i + \sum_{i=1}^n s^{(i)} x_i + \dots$$

看视

状态 \rightarrow 状态

隐马氏模型练习 Note.

No.

Date: 24. 1. 2.

$A = []_{nxn}$ a_{ij} 表示从状态 i 到状态 j 的概率

$B = []_{nxm}$ b_{ij} 表示从状态 i 到观测 j 的 P
状态 \rightarrow 观测 $\pi(,)$ 表示初始各状态的 P

看得见 两个假设 ① 状态只与 t 时有关 ② 观测只与当前状态有关

(*) 概率 calc 问题: 给定 A, B, π , 计算 $P(O|\lambda)$ O 是观测 t 是状态

前向算法

$$A = \begin{bmatrix} \frac{1}{2} & \frac{1}{5} & \frac{3}{10} \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix} \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \quad \pi = (0.2 \ 0.4 \ 0.4)^T$$

$$O = (\text{红, 白, 红})$$

状态直接

① 前向算法 $\alpha_t(i) = P(O_1, O_2 \dots O_t, i_t = q_i | \lambda)$ 转到观测 i
 \hookrightarrow t 时刻 初始 $\alpha_1(i) = \pi_i \cdot b_i(O_1)$ $i = 1, 2 \dots N$

状态为 i 的概率 前向 转移 $\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) \cdot a_{ji} \right] b_i(O_{t+1})$

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

状态先到 T 状态
再从 i 状态到观测

② 后向算法 $\beta_t(i) = P(O_{t+1}, \dots O_T | i_t = q_i, \lambda)$

初始: $\beta_T(i) = 1 \quad i = 1, 2 \dots N$

转移: $\beta_t(i) = \left[\sum_{j=1}^N \underbrace{[a_{ij} / b_j(O_{t+1})]}_{\text{注意是 } a_{ij}! \text{ 生成观测}} \right] \cdot \beta_{t+1}(j)$

从 i 到 T 状态
再从 i 状态到观测

$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(O_1) \beta_1(i)$ 从初始到观测
 用后向概率组合

前向后向写成统一形式

$$P(O|\lambda) = \sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} \underbrace{b_j(O_{t+1})}_{t=1, 2 \dots T-1} \beta_{t+1}(j)$$

前向概率练习例题.

红 白.

$$A = \begin{bmatrix} \frac{1}{2} & 0.2 & 0.3 \\ 0.3 & \frac{1}{2} & 0.2 \\ 0.2 & 0.3 & \frac{1}{2} \end{bmatrix} \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \quad \pi = (0.2, 0.4, 0.4)^T$$

$$\alpha = (\text{红}, \text{白}, \text{红}) (\text{红}, \text{白})$$

$$P(O|\lambda)$$

$$\text{初始的} \alpha_1(1) = \pi_1 \cdot b_1(O_1) = 0.2 \times 0.5 = 0.1$$

$$\alpha_1(2) = \pi_2 b_2(O_1) = 0.4 \times 0.4 = 0.16$$

$$\alpha_1(3) = \pi_3 b_3(O_1) = 0.4 \times 0.7 = 0.28$$

$$\text{转移} \alpha_2(1) = \left(\sum_{i=1}^3 \alpha_1(i) a_{i1} \right) \cdot b_1(O_2) = \dots = 0.077$$

$$\alpha_2(2) = \left(\sum_{i=1}^3 \alpha_1(i) a_{i2} \right) \cdot b_2(O_2) = \dots = 0.1104$$

$$\alpha_2(3) = \left(\sum_{i=1}^3 \alpha_1(i) a_{i3} \right) \cdot b_3(O_2) = \dots = 0.0606$$

$$P(O|\lambda) = \sum_{i=1}^3 \alpha_2(i) = 0.248$$

若用后向概率算呢?

$$\text{初始 } \beta_2(1) = \beta_2(2) = \beta_2(3) = 1$$

$$\text{转移 } \beta_1(1) = \sum_{j=1}^3 (a_{1j} \cdot b_j(O_2) \cdot \beta_2(j)) = 0.46$$

$$\beta_1(2) = \sum_{j=1}^3 (a_{2j} \cdot b_j(O_2) \cdot \beta_2(j)) = 0.51$$

$$\beta_1(3) = \sum_{j=1}^3 (a_{3j} \cdot b_j(O_2) \cdot \beta_2(j)) = 0.43$$

$$P(O|\lambda) = \sum_{i=1}^3 \beta_1(i) \cdot \pi_i \cdot b_i(O_1) = 0.248$$

当然最关键还是那道作业题!

$$A = \begin{bmatrix} \frac{1}{2} & 0.1 & 0.4 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.2 & 0.6 \end{bmatrix} \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix} \quad \pi = (0.2, 0.3, 0.5)^T$$

设 $T=8$ $O=(\text{红}, \text{白}, \text{红}, \text{红}, \text{白}, \text{红}, \text{白}, \text{白})$ 用前向后向概率

算 $P(O_4 = \text{红} | O, \lambda)$

在第4刻
为3状态

$$\begin{aligned} \text{前向算法计算后相乘: } \alpha_1(1) &= 0.2 \times 0.5 = 0.1 \\ \alpha_1(2) &= 0.3 \times 0.4 = 0.12 \\ \alpha_1(3) &= 0.5 \times 0.2 = 0.35 \end{aligned}$$

No. _____

Date. _____

$$\begin{aligned} \alpha_2(1) &= \left(\sum_{j=1}^3 \alpha_1(j) \cdot a_{j1} \right) \cdot b_1(0_2) \\ &= (0.1 \times 0.5 + 0.12 \times 0.3 + 0.35 \times 0.2) \times 0.5 = 0.078 \end{aligned}$$

$$\alpha_3(1) \alpha_2(2) = \left(\sum_{j=1}^3 \alpha_1(j) \cdot a_{j2} \right) \cdot b_2(0_2) = 0.084$$

$$\alpha_2(3) = \left(\sum_{j=1}^3 \alpha_1(j) \cdot a_{j3} \right) \cdot b_3(0_2) = 0.0822$$

$$\alpha_3(1) = \left(\sum_{j=1}^3 \alpha_2(j) \cdot a_{j1} \right) \cdot b_1(0_3) = 0.0864 \quad 0.04032$$

$$\alpha_3(2) = \left(\sum_{j=1}^3 \alpha_2(j) \cdot a_{j2} \right) \cdot b_2(0_3) = 0.026496$$

$$\alpha_3(3) = \left(\sum_{j=1}^3 \alpha_2(j) \cdot a_{j3} \right) \cdot b_3(0_3) = 0.068124$$

$$\dots \alpha_4(1) = 0.0208668 \quad \alpha_4(2) = 0.01236192 \quad \alpha_4(3) = 0.0436112$$

$$\text{后向算法计算后相乘: } \beta_7(1) = \beta_7(2) = \beta_7(3) = 1$$

$$\beta_7(1) = \sum_{j=1}^3 (a_{1j} \cdot b_j(0_7)) \beta_8(j) \cdot b_j(0_8) = 0.43$$

$$\beta_7(2) = \sum_{j=1}^3 (a_{2j} \cdot \beta_8(j)) \cdot b_j(0_8) = 0.51$$

$$\beta_7(3) = \sum_{j=1}^3 (a_{3j} \cdot \beta_8(j)) \cdot b_j(0_8) = 0.4$$

$$\beta_6(1) = \left(\sum_{j=1}^3 a_{1j} \beta_7(j) \cdot b_j(0_7) \right) = 0.1861$$

$$\beta_6(2) = \left(\sum_{j=1}^3 a_{2j} \beta_7(j) \cdot b_j(0_7) \right) = 0.2415$$

$$\beta_6(3) = \left(\sum_{j=1}^3 a_{3j} \beta_7(j) \cdot b_j(0_7) \right) = 0.1762$$

$$\dots \beta_5(1) = 0.105521 \quad \beta_5(2) = 0.100883 \quad \beta_5(3) = 0.111934$$

$$\dots \beta_4(1) = 0.04586531 \quad \beta_4(2) = 0.05276409 \quad \beta_4(3) = 0.04277618$$

$$P(i_4 = g_3 | 0, \lambda) = \frac{\alpha_4(3) \cdot \beta_4(3)}{\alpha_4(1) \beta_4(1) + \alpha_4(2) \beta_4(2) + \alpha_4(3) \beta_4(3)} \approx 0.5368638876$$

第4步为状态3

EM 算法

中间的相联定理全写上了，关键是要会用它！ ⑨ 要估计的参数

Y: 观测到的随机变量的数据 Z: 隐变量的数据 (Y, Z) 完全
 $P(Y|Z)$ 为要估计的 $P(Y|Z)$ (在给定 θ 下的 PDF)

Y, Z 联合 $P(Y, Z|\theta)$ $\log: \log P(Y, Z|\theta)$

θ 初始为 $\theta^{(0)}$ $\rightarrow Q(\theta, \theta^{(i)}) = E_Z [\log P(Y, Z|\theta) | Y, \theta^{(i)}]$
 随机取

E步
期望

关于隐变量！

但是 E() 但是
 $\log(Y, Z|\theta)$!

$$\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)})$$

$$Q(\theta, \theta^{(i)}) = E_Z ()$$

$$= \sum_z \log P(Y, Z|\theta^{(i)}) P(Z|Y, \theta^{(i)})$$

以 GMM 为例，来理解一下 EM

（n）说：虽然课上不细讲，

在给定 $Y, \theta^{(i)}$ 前提下，对 Z 的条件概率的期望！

但不妨碍她考，我要自己证明一遍

GMM 核心：假设来自一个类的样本均服从同一正态分布

第 k 个类 $N_p(M_k, \Sigma_k)$ $k=1, 2, \dots, K$ 是参数

$$f(x_i) = (2\pi)^{-\frac{p}{2}} |\Sigma_k|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - M_k)^T \Sigma_k^{-1} (x_i - M_k) \right\} \quad i=1, 2, \dots, n$$

x_i 为 p 维向量

如果我知道 第 i 个样本来自于第 k 个高斯分布，则

$$f_{ik} = \begin{cases} 1 & x_i \text{ 来自 } N_k \\ 0 & \text{其他} \end{cases}$$

$f_i = [f_{i1} \dots f_{iK}]^T$ 独立同分布，服从多维分布 $M(1, \pi_1, \dots, \pi_K)$

$$\pi_k = P(f_{ik} = 1) \quad \sum_{i=1}^K \pi_i = 1$$

$$f_i \text{ 的 PDF } f(f_i) = \prod_{k=1}^K (\pi_k)^{f_{ik}}$$

$$f(x_i | f_i) = \prod_{k=1}^K \left((2\pi)^{-\frac{1}{2}} |\Sigma_k|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k) \right\} \right)^{f_{ik}}$$

完全数据 (x_i, f_i) 的联合 PDF:

§. 隐变量

$$p(\theta) = \prod_{i=1}^n f(x_i | \theta) = \prod_{i=1}^n f(\theta) f(x_i | \theta)$$

$$(x_i, s_i) \text{ 的概率} = \prod_{i=1}^n \prod_{k=1}^K \left(\pi_k (2\pi)^{-\frac{p}{2}} |\Sigma_k|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k) \right\} \right)^{s_{ik}}$$

这个也是 $\theta = (\pi_1 \dots \pi_K, \mu_1, \dots, \mu_K, \Sigma_1 \dots \Sigma_K)$ 的似然函数。

$$f(x_1) = \sum_{k=1}^K \pi_k \cdot f(x_1; \mu_k, \Sigma_k)$$

$$\ln L(\theta) = \ln \left(\prod_{i=1}^n \prod_{k=1}^K \left(\pi_k (z^x)^{-\frac{1}{2}} / |\Sigma_k|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k) \right\} \right)^{f_{ik}} \right)$$

尽量和
有关

$$\alpha = -\frac{1}{2} \sum_{i=1}^n \sum_{k=1}^K f_{ik} \cdot \left((x_i - \mu_k)^T \Sigma_k^{-1} (x_i - \mu_k) \right) + \ln |\Sigma_k|$$

$$\text{近似} + \sum_{j=1}^n \sum_{k=1}^K f_{ik} \ln(x_k) = Q_0(\theta)$$

E步：目标求 $E_{f_i}(\vartheta_{0(t)}) | x_i, \vartheta^{(t)})$

s_i - 大堆, 但拆开来有 k 个数. 设 s_{ik} 期限为 ∞

$$\text{则 } Q(\theta) \text{ 所求} = -\frac{1}{2} \sum_{i=1}^n \sum_{k=1}^K \pi_k (x_i) + \sum_{i=1}^n \sum_{k=1}^K \pi_{ik}^* \ln(x_i)$$

$$\pi_{ik}^* = E(f_{ik}|x_i) \div P(f_{ik}=1|x_i) = \frac{\pi_k \psi(x_i; \mu_k, \Sigma_k)}{\sum_{k=1}^K \pi_k \psi(x_i; \mu_k, \Sigma_k)}$$

个体的 \swarrow
类别期望? 其中 $\psi(x_i; \mu_k, \Sigma_k)$ 为第 k 个

M步：让 $Q(\theta)$ 关于 θ 取最大值。

$Q_1(\theta)$ 与 M_k, Σ_k 有关

No.

Date.

$$Q(\theta) = -\frac{1}{2} \sum_{i=1}^n \sum_{k=1}^K \pi_{ik}^* \left((x_i - M_k)^T \Sigma_k^{-1} (x_i - M_k) + \ln |\Sigma_k| \right)$$

$$+ \sum_{i=1}^n \sum_{k=1}^K \pi_{ik}^* \ln(\pi_k) \rightarrow Q_2(\theta) \rightarrow \text{与 } \pi_k \text{ 有关}$$

$$\left[\begin{array}{l} \frac{\partial Q_1(\theta)}{\partial M_k} \propto \sum_{i=1}^n \pi_{ik}^* \Sigma_k^{-1} (x_i - M_k) \\ \frac{\partial Q_1(\theta)}{\partial \Sigma_k} \propto \sum_{i=1}^n \pi_{ik}^* \left(-\Sigma_k^{-1} (x_i - M_k) (x_i - M_k)^T \Sigma_k^{-1} + \Sigma_k^{-1} \right) \end{array} \right]$$

$$\text{由此 } M_k = \frac{\sum_{i=1}^n \pi_{ik}^* \cdot x_i}{\sum_{i=1}^n \pi_{ik}^*}$$

$$\Sigma_k = \frac{\sum_{i=1}^n \pi_{ik}^* (x_i - M_k) (x_i - M_k)^T}{\sum_{i=1}^n \pi_{ik}^*}$$

$Q_2(\theta)$ 才解用到拉格朗日乘子法
(因为 $\sum_k \pi_k = 1$)

$$\text{可得 } \pi_k = \frac{1}{n} \sum_{i=1}^n \pi_{ik}^*$$

$$\phi(x_i; M_k, \Sigma_k) = (2\pi)^{-\frac{p}{2}} |\Sigma_k|^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (x_i - M_k)^T \Sigma_k^{-1} (x_i - M_k) \right\}$$

2024.1.2.

No.
GMM
Date.

之前我有一页 Note, 但当找不到时, 就是用 EM 推证 GMM

虽然自己时间确实有限, 但 GMM 实在太重要了, 我还是再写一下吧!
什么是 EM algo? 观测到的数据; 未观测到的~

$$P(Y|\theta) = \sum_z P(z|\theta) P(Y|z, \theta) \quad (\text{可观测到的, 又可观测到的.})$$

$$\hat{\theta} = \arg \max_{\theta} \log P(Y|\theta) \quad \theta = (\pi, P, \gamma) \text{ 参数}$$

联合分布 $P(Y, Z|\theta)$ 条件分布 $P(Y|Z|\theta)$ 已知求给定 Y 和当前参数估计 $\theta^{(i)}$ 下隐变量 Z 的条件概率分布

$$Q(\theta, \theta^{(i)}) \leftarrow E_Z \left[\log P(Y, Z|\theta) \mid Y, \theta^{(i)} \right]$$

$$\text{M步, 求使 } Q(\theta, \theta^{(i)}) \text{ max 的 } \theta^{(i+1)} = \sum_z \log P(Y, Z|\theta) P(Z|Y, \theta^{(i)})$$

重复 E, M, 直至收敛 (前面是 GMM 证明过程)

$$\text{高斯混合模型: } P(Y|\theta) = \sum_{k=1}^K \alpha_k \phi(y|\theta_k) \quad \begin{cases} \alpha_k \geq 0 \\ \sum_k \alpha_k = 1 \end{cases}$$

 $\phi(y|\theta_k)$ 是高斯分布 PDF: $\theta_k = (m_k, \sigma_k^2)$

$$\phi(y|\theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp \left\{ -\frac{1}{2\sigma_k^2} (y - m_k)^2 \right\} \quad \text{第 } k \text{ 个模型.}$$

$$\text{GMM: } P(Y|\theta) = \sum_{k=1}^K \alpha_k \phi(y|\theta_k) \quad \theta = (\alpha_1, \alpha_2, \dots, \alpha_K, \theta_1, \dots, \theta_K)$$

可观测数据 y_1, \dots, y_N 是怎样产生的?依据概率 α_k 选择第 k 个 $\phi(y|\theta_k)$, 然后产生 y_i y_i 已知, 但 y_i 来自第 k 个模型却未知 \rightarrow 隐变量, 用 r_{jk} 表示

$$r_{jk} = \begin{cases} 1 & y_i \text{ 来自第 } k \text{ 个分模型} \\ 0 & \text{其他} \end{cases}$$

完全数据: $(y_1, r_{11}, \dots, r_{1K}, y_2, r_{21}, \dots, r_{2K}, \dots)$

起點

GMM的證明

Date.

完全数据 $(y_1, Y_{11} Y_{12} \dots Y_{1K}, y_2, Y_{21} \dots Y_{2K}, \dots)$

$Y_{jK} = \begin{cases} 1 & \text{表示 } y_j \text{ 来自模型 } K \\ 0 & \text{其他} \end{cases}$

完全数据的似然函数

$$P(y, \gamma | \theta) = \prod_{j=1}^N P(y_j, Y_{j1}, \dots, Y_{jK} | \theta)$$

$$= \prod_{j=1}^N \prod_{K=1}^K [\alpha_K \psi(y_j | \theta_K)]^{Y_{jK}}$$

来自也要遵循概率

$$= \prod_{K=1}^K \alpha_K^{n_K} \prod_{j=1}^N [\psi(y_j | \theta_K)]^{Y_{jK}}$$

$$n_K = \sum_{j=1}^N Y_{jK}, \quad \sum_{K=1}^K n_K = N$$

$$= \prod_{K=1}^K \alpha_K^{n_K} \prod_{j=1}^N \left[\frac{1}{\sqrt{2\pi\sigma_K^2}} \exp\left(-\frac{(y_j - \mu_K)^2}{2\sigma_K^2}\right) \right]^{Y_{jK}}$$

$$\log P(y, \gamma | \theta) = \sum_{K=1}^K \left\{ n_K \log \alpha_K + \sum_{j=1}^N \left[\log\left(\frac{1}{\sqrt{2\pi\sigma_K^2}}\right) - \log \psi(y_j | \theta_K) \right] \right\}$$

$$E: Q(\theta, \theta^{(i)}) = E_{\gamma} \left(\log(y, \gamma | \theta) | y, \theta^{(i)} \right) \rightarrow \text{关于 } \gamma \text{ 的期望}$$

$$= \sum_{K=1}^K \left[\sum_{j=1}^N E(Y_{jK}) \right] (\log \alpha_K) + \sum_{K=1}^K \sum_{j=1}^N E(Y_{jK}) \left[\log\left(\frac{1}{\sqrt{2\pi\sigma_K^2}}\right) - \log \psi(y_j | \theta_K) \right]$$

$$E(Y_{jK} | y, \theta^{(i)}) = ? = \hat{Y}_{jK} = P(Y_{jK}=1 | y, \theta^{(i)}) \cdot 1 - \frac{1}{2\sigma_K^2} (y_j - \mu_K)^2$$

$$= \frac{P(Y_{jK}=1, y_j | \theta^{(i)})}{\sum_{j=1}^K P(Y_{jK}=1, y_j | \theta^{(i)})} = \frac{\sum_{j=1}^K P(y_j | Y_{jK}=1, \theta^{(i)}) \cdot P(Y_{jK}=1 | \theta^{(i)})}{\sum_{j=1}^K P(y_j | Y_{jK}=1, \theta^{(i)}) \cdot P(Y_{jK}=1 | \theta^{(i)})}$$

$$= \alpha_K \psi(y_j | \theta_K)$$

再将 Y_{jK} 代入，可得

$$Q(\theta, \theta^{(i)}) = \dots$$

EM, M步看 Note, P80

课程名称: 统计方法与机器学习

学生姓名: _____ 学号: _____

专业: _____ 年级/班级: _____

课程性质: 专业必修课

一	二	三	四	五	六	总分	阅卷人签名

一、(本题共 20 分)

表 1 是一个不完整的双因素方差分析表。

表 1 不完整的双因素方差分析表

来源	自由度	平方和	均方	F统计量	p 值
因素 A	/	/	0.0833	0.05	0.952
因素 B	/	96.333	96.333	57.80	<0.001
交互效应	2	12.167	6.0833	3.65	/
AB					
误差	6	10	/		
汇总	11	118.667			

$$SS_A = \sum_{i=1}^a \sum_{j=1}^m (y_{ij} - \bar{y}_{..})^2$$

请根据表 1 回答以下问题:

- (2 分) 因素 A 的平方和 SS_A 是 0.167 这什么意思啊?
- (2 分) 因素 A 的自由度为 1
- (2 分) 在实验中, 因素 B 的水平数为 2
- (2 分) 均方误差为 1.667
- (2 分) 在这个实验中, 每种组合的重复次数为 2
- (5 分) 如何计算交互效应的 p 值? 并给定显著性水平 $\alpha = 0.05$ 时, 简述如何判断交互效应的显著性。
- (5 分) 证明: 在双因素方差分析中, $SS_T = SS_A + SS_B + SS_{AB} + SS_E$ 。

1 层次聚类适用范围广
但边界模糊时效慢

2 K-means 收敛慢且依赖初始中心点

3 GMM

4 DBSCAN 基于密度

5 不适合稀疏数据集。而且数据维度高。而且参数太多。

6 聚类有相关关系的情况

7 影响还很大

8 该模型是否显著。 $F \leq F_{\alpha}$ 到拒绝域，故显著。判定拟合程度。

9 偏差平方 Var Biass
方差 Var
均方误差 MSE

10 $MSE = Biass + Var$

11 MSE 先小后大
方差较小时候
方差较大时候
偏差较小偏差平方大

12 变量多，偏差平方较小
但是方差较大，过拟合

13 $K - \beta(K)$

14 1. (5 分) 同学 A 想构建利用 X_1 来预测 y ，从而构建了一个一元线性回归模型。请根据图 3 中 Python 运行的结果，写出一元线性回归模型，并从一个角度阐述该模型是否显著。

15 $\hat{y} = 0.6954 + 1.6034x$

16 $R^2 = \frac{SSR}{SSE} = \frac{F_0}{n-p-1}$

17 $F_0 = \frac{F_{\alpha}}{n-p-1}$

18 实际问题
外部有效性和纯度
内部决定系数 R^2

19 图 2 前 5 条数据的示意图

20 现有一个数据集，其中包含 400 条观测，每条观测有 1 个因变量 y 以及 20 个中心化后的特征 x_1, x_2, \dots, x_{20} 。前 5 行数据如图 2 所示。

	y	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	\dots	x_{11}	x_{12}	x_{13}	x_{14}	x_{15}	x_{16}	x_{17}	x_{18}	x_{19}	x_{20}
0	-1.24	0.31	-0.95	-0.99	-0.58	-0.47	0.70	-0.88	1.05	0.03	\dots	-1.42	-0.85	-0.37	-0.52	-0.19	-1.75	0.78	-0.78	0.23	0.05
1	-0.72	-0.04	-2.58	1.32	-0.75	-0.92	1.43	-1.85	-0.83	1.36	\dots	0.31	-0.01	0.49	-1.20	0.08	-0.83	-0.98	2.89	-0.79	-0.82
2	6.40	-0.89	0.91	-0.07	0.14	1.31	0.60	0.34	-0.96	1.67	\dots	1.58	0.44	1.80	-0.04	1.65	-0.06	-1.01	-0.87	-0.41	-1.03
3	1.10	1.81	0.20	-0.70	-1.03	0.72	-0.89	1.58	-0.03	-0.28	\dots	0.61	0.01	-1.39	-0.78	-1.20	-2.09	-0.70	-0.73	-1.96	0.48
4	2.33	0.15	-0.27	-0.82	-0.21	0.42	-0.15	-0.04	0.80	2.55	\dots	-0.44	-0.47	-1.08	-2.31	0.87	-0.62	1.10	1.02	1.26	0.58

21 图 3 Python 的运行结果 (一个特征)

22 2. (5 分) 根据图 3 中 Python 运行的结果，请给出当 X_1 的取值为 0.5 时， y 的点预测。同时，阐述如何计算其 $1 - \alpha$ 的预测区间。

23 3. (5 分) 同学 B 将特征 X_1 和 X_2 同时纳入线性回归模型，并利用 Python 得到结果，如图 4 所示。将图 3 和图 4 进行比较，发现在线性回归模型中 R^2 从 0.127 提升到了 0.320，即结果为 $R^2_{mod_1} = 0.127 \leq R^2_{mod_2} = 0.320$ 。请问这个结论是否普遍成立？

24 $\hat{y}_0 = \mathbf{x}_0^T (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \mathbf{y}$

25 $\hat{y}_0 \sim N(\mathbf{x}_0^T \mathbf{\beta}, \mathbf{x}_0^T \mathbf{x} (\mathbf{x}^T \mathbf{x})^{-1} \mathbf{x}^T \mathbf{x})$

26 $\hat{\beta} \sim N(\beta, \mathbf{x}^T \mathbf{x} (\mathbf{x}^T \mathbf{x})^{-1})$

27 $\hat{y} - \hat{y}_0 \sim N(0, \mathbf{x}^T \mathbf{x} (\mathbf{x}^T \mathbf{x})^{-1})$

问题其实在说： X 变多了， R^2 变大这件事普遍有吗？
 No! X_1, X_2 有在线性关系时，如 X_1 为男性 X_2 表示女性 $X_1 + X_2 = 1$
 在 X_1 的基础上增加 X_2 不会提升 R^2 y my 写错了其实 R² = $\frac{SSR}{SS_T} = 1 - \frac{SS_E}{SS_T}$
 SST不变 $R^2_{\text{pri}} \geq R^2_{\text{pri}}$...具体推证略

遍存在？如果是，请证明它；如果不是，请举出反例。

Dep. Variable:	y	R-squared:	0.320			
Model:	OLS	Adj. R-squared:	0.317			
Method:	Least Squares	F-statistic:	93.54			
Date:	Fri, 02 Dec 2022	Prob (F-statistic):	5.19e-34			
Time:	17:04:30	Log-Likelihood:	-1070.5			
No. Observations:	400	AIC:	2147.			
Df Residuals:	397	BIC:	2159.			
Df Model:	2					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.6500	0.177	3.682	0.000	0.303	0.997
X1	1.4421	0.187	7.728	0.000	1.075	1.809
X2	1.8526	0.174	10.618	0.000	1.510	2.196
Omnibus:	2.166	Durbin-Watson:	2.004			
Prob(Omnibus):	0.339	Jarque-Bera (JB):	2.246			
Skew:	-0.169	Prob(JB):	0.325			
Kurtosis:	2.859	Cond. No.	1.12			

图 4 Python 的运行结果（两个特征）

4. (5 分) 经验所知， R^2 越大表明特征的拟合效果越好。于是，同学 C逐一将特征放入线性回归模型中。具体方案是，第一个模型的特征是 X_1 ；第二个模型的特征是 X_1 和 X_2 ；第三个模型的特征是 X_1, X_2 和 X_3 ，以此类推。结果发现 R^2 的数值如表 1 所示。

表 1 20 个模型中不同特征维度下的 R^2 值

维度	1	2	3	4	5	6	7	8	9	10
R^2	0.127	0.320	0.495	0.568	0.637	0.707	0.779	0.841	0.902	0.948
维度	11	12	13	14	15	16	17	18	19	20
R^2	0.949	0.950	0.950	0.950	0.950	0.950	0.950	0.950	0.950	0.952

请问， R^2 是否适合作为模型选择的指标？并请说明理由。如果不是，请给出一个改进方案。y my: 不适合

因为特征越多，通常会使 R^2 提升
 这种方法未考虑模型的复杂程度
 容易过拟合，改进方案：
 使用AIC或BIC作模型选择的指标
 $\hat{R}^2 = 1 - \frac{n-1}{n-p-1} (1 - R^2)$

$$\text{线性SVM} \min_{w, b} L(w, b) = \frac{1}{2} \|w\|^2$$

三、(本题共 10 分)

请阐述一下, 如何诊断出数据中存在多重共线性? (提示: 只需要提供一种完整的方案)。

$$\text{感知机} \min_{w, b} L(w, b) = -\sum_{i \in M} y_i (w x_i + b)$$

四、(本题共 15 分)

比较感知机和线性 SVM 的损失函数。

$$\text{感知机: } L(w, b) = -\sum_{i \in M} y_i (w x_i + b)$$

线性SVM损失函数???
难道是那个问题 \min 吗?

五、(本题共 10 分) $P(x|y)$ $P(y|x)$

1. (5 分) 解释生成式模型和判别式模型, 并分析二者的不同点;

2. 列出三种判别式模型 (3 分) 和两种生成式模型 (2 分)

SVM 感知机 决策树

随机森林, 朴素贝叶斯

QMM 贝叶斯模型 (生成式)

六、(本题共 25 分)

考虑利用线性支持向量机对如下两类可分数据进行分类:

$$+1: (1,1), (2,2), (2,0)$$

$$-1: (0,0), (1,0), (0,1)$$

1. (8 分) 在图中做出这 6 个训练点, 构造具有最优超平面和最优间隔的权重向量:

2. (4 分) 哪些是支撑向量?

3. (13 分) 通过寻找拉格朗日乘子来构造在对偶空间的解, 并将它与第一小问中的结果比较。

$$\begin{aligned} 1. \min_{w, b} \frac{1}{2} \|w\|^2 &= \frac{1}{2} (w_1^2 + w_2^2) \\ \text{s.t. } w_1 + w_2 + b &\geq 1 \\ 2w_1 + 2w_2 + b &\geq 1 \\ 2w_1 + b &\geq 1 \\ -b &\geq 1 \\ -(w_1 + b) &\geq 1 \\ -(w_2 + b) &\geq 1 \end{aligned}$$

$$\begin{aligned} 2. \text{取 } f(x_1) = y_1 (w x_1 + b) \\ f(x_1) = 1, f(x_2) = 5, f(x_3) = 1 \\ f(x_4) = 3, f(x_5) = 1, f(x_6) = 1 \\ \text{故 } (1,1), (1,0), (0,1), (2,0) \text{ 为 } \dots \end{aligned}$$

$$3. \text{构造 } \min_{\alpha} \sum_{i=1}^6 \sum_{j=1}^6 \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^6 \alpha_i$$

$$\text{s.t. } \boxed{\sum_{i=1}^6 \alpha_i y_i = 0} \star$$

解得 $w_1 = 2$

$$w_2 = 2$$

$$b = -3$$

故 $\text{最优超平面 } 2x^{(1)} + 2x^{(2)} - 3 = 0$

$$\text{权重向量 } (w^T, b) = (2, 2, -3)$$

$$+ 4\alpha_1 \alpha_2 + 2\alpha_1 \alpha_3 - \alpha_1 \alpha_5 - \alpha_1 \alpha_6$$

$$+ 4\alpha_2 \alpha_3 - 2\alpha_2 \alpha_5 + 2\alpha_2 \alpha_6$$

$$- 2\alpha_3 \alpha_5 - (\alpha_1 + \alpha_2 + \alpha_3 + \alpha_4 + \alpha_5 + \alpha_6)$$

$$\text{s.t. } \boxed{\alpha_1 + \alpha_2 + \alpha_3 - \alpha_4 - \alpha_5 - \alpha_6 = 0}$$

$$\alpha_i \geq 0$$

$$w^* = \sum_{i=1}^6 \alpha_i^* y_i x_i, b^* = y_j - \sum_{i=1}^6 \alpha_i^* y_i (x_i \cdot x_j)$$

Start-m1 最后一晚边默写边梳理

2024.1.11. 晚

$\hat{\sigma}^2$ -一样

期末: 2024.1.12, 13:00 - 15:00

我各种资料都参考一下.

效应模型 $y_{ij} = M + \alpha_i + \varepsilon_{ij}$ $i=1, 2, \dots, a$ $j=1, 2, \dots, m$, $\varepsilon_{ij} \sim N(0, \hat{\sigma}^2)$ 方法: F检验.

约束 $\sum_{i=1}^a \alpha_i = 0$

要检验的问题 $H_0: M_1 = M_2 = \dots = M_a$

VS $H_1: \dots$

$\frac{SS_A}{\hat{\sigma}^2} \sim \chi^2(a-1)$ $\frac{SS_A}{\hat{\sigma}^2} \sim \chi^2(a-1)$ 则 $F_0 \sim \frac{\frac{SS_A}{a-1}}{\frac{SS_E}{n-a}}$ $F_0 > F_{1-\alpha}(a-1, n-a)$ 拒绝!

$$E(SS_A) = \hat{\sigma}^2 \cdot (a-1) + \left| \sum_{i=1}^a \alpha_i^2 \right|$$

$$SS_A + SS_E = SS_T$$

$$SS_A = \sum_{i=1}^a \sum_{j=1}^m (\bar{y}_{ij} - \bar{y}_{..})^2$$

$$SS_E = \sum_{i=1}^a \sum_{j=1}^m (\bar{y}_{..} - y_{ij})^2$$

$$SS_T = \sum_{i=1}^a \sum_{j=1}^m (y_{ij} - \bar{y}_{..})^2$$

参数估计 $\hat{M} = \bar{y}_{..}$

$$\hat{\alpha}_i = \bar{y}_{i..} - \bar{y}_{..}$$

$$\hat{\sigma}^2 = \frac{SS_E}{n-a}$$

有一对样本 (i, j)

$$\bar{y}_{i..} \sim N(M_i, \frac{\hat{\sigma}^2}{m}) \quad \bar{y}_{j..} \sim N(M_j, \frac{\hat{\sigma}^2}{m})$$

$$\bar{y}_{i..} - \bar{y}_{j..} \sim N(M_i - M_j, \frac{2\hat{\sigma}^2}{m})$$

构造 t 分布

$$t_0 = \frac{\frac{(\bar{y}_{i..} - \bar{y}_{j..}) - (M_i - M_j)}{\sqrt{\frac{\hat{\sigma}^2}{m}}}}{\sqrt{\frac{SS_E}{n-a}}} \sim t(n-a)$$

现在就知道

多重比较任务

$|\bar{y}_{i..} - \bar{y}_{j..}| < M_i - M_j$ 不能太大

$$Tukey P(w) = P(U \{ |\bar{y}_{i..} - \bar{y}_{j..}| \geq c \})$$

拒绝

关键在于构造 t 检验统计量

不断转化, 直至拆分

$\bar{y}_{i..}$ 分布, 怎样构造?

$$\bar{y}_{i..} \sim N(M_i, \frac{\hat{\sigma}^2}{m})$$

构造 1 个即可, 不用两个!

都检验统计量!

假设 $M_1 = M_2 = \dots = M_a$ (H_0)

$$\frac{\frac{\bar{y}_{i..} - M_i}{\sqrt{\frac{\hat{\sigma}^2}{m}}}}{\sqrt{\frac{SS_E}{n-a}}} = \frac{\bar{y}_{i..} - M_i}{\hat{\sigma}} \sim t(n-a)$$

t 极差 $t(n-a)$ 的 $\max - \min \leq \dots$ 临界值 get!

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \varepsilon_i$$

$$E(\varepsilon_i) = 0, \text{Var}(\varepsilon_i) = \hat{\sigma}^2$$

$$\dots$$

$$y = X\beta + \varepsilon, E(y) = X\beta, \text{Var}(y) = \hat{\sigma}^2 I_n$$

$$\hat{\beta} = (X^T X)^{-1} X^T y, E(\hat{\beta}) = \beta$$

$$\text{Var}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

$$\text{拟合值 } \hat{y} = X\hat{\beta} = Hy$$

$$H = H^2, \text{Tr}(H) = p+1$$

$$\hat{e} = \hat{y} - y, e = y - \bar{y}$$

$$= (I - H)y$$

$$y^T e = 0, \text{Var}(e) =$$

$$\frac{\partial (X^T B X)}{\partial X} =$$

$$X^T X$$

$$(B + B^T) X$$

$$| n \geq p+1 |$$

$$\text{样本量比模型参数大} |$$

$$\text{Var}(e) = \text{Var}((I-H)y) = \text{Cov}((I-H)y, (I-H)y) = (I-H) \text{Cov}(y, y) (I-H)^T$$

$$= (I-H) \cdot f^* I_n (I-H) = f^* (I-H)^2 = f^* (I-H)$$

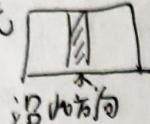
$$\star \text{Cov}(Ax, By) = A \text{Cov}(x, y) B^T \quad \text{Var}(Ax + c) = A \text{Var}(x) A^T$$

$\text{Cov}(\hat{\beta}, e) = 0$ 线性不相关. $\hat{\beta}$ 与 $SS_E = e^T e$ 独立.

$$SS_T = SS_R + SS_E \quad SS_T = \sum_{i=1}^n (y_i - \bar{y})^2 \quad SS_R = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \quad SS_E = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

$$SS_R \sim \frac{SS_E}{f^*} \sim \chi^2(P) \quad \frac{SS_E}{f^*} \sim \chi^2(n-P-1)$$

$$\text{中心化} \quad X_C = (I-H_1) X \quad I_n^T (I-H_1) = 0$$



$$\hat{\beta}_C, \text{intercept} = 0$$

$$\hat{\beta}_C, \text{slope} = \beta_0, \text{slope}$$

$$L_{ij} = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2, \quad L_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$X_C = X_C L$$

$$\hat{\beta}_3, \text{intercept} = 0, \quad \hat{\beta}_3, \text{slope} = \frac{1}{\sqrt{L_{yy}}} L^T \hat{\beta}_C, \text{slope}$$

$$\hat{\beta}_{Sj} = \frac{1}{\sqrt{L_{yy}}} \hat{\beta}_{Cj} = \frac{\sqrt{L_{ij}}}{\sqrt{L_{yy}}} \hat{\beta}_j$$

第j分量

t检验 \rightarrow 回归系数

F检验: 模型合理吗? $H_0: \beta_1 = \beta_2 = \dots = 0$

$$F_0 = \frac{\frac{SS_R}{P}}{\frac{SS_E}{n-P-1}} \sim F(P, n-P-1)$$

$$\text{拟合值} \quad \hat{y}_i = x_i^T \hat{\beta} \quad \text{偏差} \quad e_i = y_i - \hat{y}_i$$

t检验: 删去次要的自变量 $H_{0j}: \beta_j = 0 \quad \text{vs} \quad H_{1j}$

$$x \sim N(\mu, \Sigma) \quad Ax + b \sim N(A\mu + b, A\Sigma A^T) \quad \hat{\beta} \sim N(\beta, f^2(X^T X)^{-1})$$

$$\text{检验统计量} \quad t_{ij} = \frac{\hat{\beta}_j \frac{1}{\sqrt{L_{jj}}}}{\sqrt{\frac{SS_E}{f^2(n-P-1)}}} = \frac{\hat{\beta}_j}{\sqrt{\frac{SS_E}{f^2(n-P-1)}} \cdot \sqrt{C_{jj}}} \quad \text{且} \quad \hat{\beta}_j \sim N(\beta_j, f^2 C_{jj})$$

$$\sim t(n-P-1) \quad \text{此处} \quad f^2 = \frac{SS_E}{n-P-1}$$

$$R^2 = \frac{SS_R}{SS_T}$$

$\hat{\beta}_j$ 已求得, β_j 我们未知, 但能判定.

$$R = \sqrt{R^2}$$

$$\hat{y}_0 = x_0^T \hat{\beta} \quad E(\hat{y}_0) = G(y_0) \quad y_0 \sim N(x_0^T \beta, f^2)$$

相关系数 $R = \sqrt{R^2}$

整体的 $x \dots x_0^T y$

线性关系

y_0 的线性无偏预测中, \hat{y}_0 最小.

$$\hat{\beta} \sim N(\beta, f^2(X^T X)^{-1}) \quad \hat{y}_0 \sim N(x_0^T \beta, f^2 x_0^T (X^T X)^{-1} x_0)$$

$$\text{故} \quad y_0 - \hat{y}_0 \sim N(0, f^2 (I + x_0^T (X^T X)^{-1} x_0))$$

相关系数: 单个 - 线性关系

再凑 t 分布 (用 $\frac{SS_E}{n-P-1}$ 搞 \hat{y}_0 的置信区间, $E(\hat{y}_0)$ 区间就是 $\sqrt{f^2}$ 乘 \hat{y}_0 是 $\sqrt{f^2}$ 类似的)

欠拟合: $\hat{\beta}$, $\hat{\gamma}$ 有偏估计; 有偏预测预测方差小.

过拟合: $\hat{\beta}$, $\hat{\gamma}$ 无偏; 无偏预测; 预测方差大.

SSE , R^2 不能用于变量选择. 自变量较少, $SSE \downarrow$ $SSE^{q+1} \leq SSE^q$

$$R^2_{q+1} \geq R^2_q \quad \text{修正} \quad \tilde{R}^2 = 1 - \frac{n-1}{n-p_1} (1 - R^2) \quad \text{惩罚项}$$

$$AIC = -2\ln(\text{模型最大似然}) + 2(\text{模型独立参数数})$$

$$BIC = -2\ln(\text{模型最大似然}) + \ln(n) \cdot ($$

自变量很多 删进法/后退法 (逐步回归)

自变量间相关性弱 \rightarrow 很好 相关性强 \rightarrow 违背模型假设

设置太多虚拟变量 符合理想

$$X_m = 1 \text{ (男性)} \quad X_f = 1 \text{ (女性)} \quad \text{个人收入}$$

$$X_m = 1 - X_f \quad X_f \text{ 完全由 } X_m \text{ 完全} \quad \text{家庭收入}$$

没必要把两个虚拟变量同时纳入 model

$$\text{仅仅把 } X \text{ 标准化 } \text{Var}(\hat{\beta}_j) = \frac{c_{jj}}{L_{jj}} \sigma^2.$$

$$c_{jj} = \frac{1}{1 - R_j^2} \quad R_j^2: \text{以 } X_j \text{ 为因变量}$$

$R_j^2 \downarrow VIF_j$.
多重共线性严重

$$VIF = \frac{1}{R^2} \sum_{j=1}^p VIF_j$$

多重共线性方法

删除自变量 (重要)

增加样本量

改进最小二乘估计 (岭回归, PIA)

岭回归 $\hat{\beta}(k) = (X^T X + kI)^{-1} X^T y$ $\hat{\beta}(k)$ 是有偏估计

分子方误差 $MSE(\hat{\beta}(k)) \leq MSE(\hat{\beta}(0))$

$$MSE(\hat{\beta}(k)) = E((\hat{\beta}(k) - \beta)^T (\hat{\beta}(k) - \beta))$$

$$A \text{ 对称. } E(X^T A x) = \text{Tr}(A \Sigma) + M^T A M$$

$$\Sigma = \text{Var}(u) \quad M = E(x)$$

另一方面看岭回归估计:

$$L_2 \text{ 范数}$$

$$\text{对 } k > 0$$

$$\|\hat{\beta}(k)\| < \|\beta\|$$

$$\min (y^T X \beta)^2 (y^T X \beta)$$

$$\text{s.t. } \beta^T \beta \leq s$$

通过 $k - \hat{\beta}_j(k)$ (第j个分量) \rightarrow 选岭迹大致稳定的.

参数k的选择 \rightarrow 增扩因子. $c_{jj} > VIF$ (有多重...)

$$\text{Var}(\hat{\beta}(k)) = \sigma^2 (X^T X + kI)^{-1} X^T X (X^T X + kI)^{-1} = \sigma^2 C(k)$$

$$C(k) \text{ 的对角线元素 } c_{jj}(k) \rightarrow \text{新的VIF} \quad k \uparrow \quad c_{jj}(k) \downarrow$$

选k使所有 $c_{jj}(k) \leq VIF$ 通过k.

$$X = (x_1, x_2, \dots, x_p) \text{ 标准化, } x_i$$

$$(X^T X)^{-1} = C = (c_{ij})_{p \times p}$$

$$c_{jj} = VIF_j \text{ 增扩因子, } x_j \text{ 的}$$

$$\hat{\beta}_{sj} = \frac{\hat{\beta}_j}{\sqrt{c_{jj}}} \quad (\text{对 } x_j \text{ 都标准})$$

$$X^T X \text{ 有一个特征值近似为 } 0$$

$$\text{则 } X \text{ 的列向量间存在多重共线性}$$

$$x_j^T x_j \text{ 特征值 } \lambda_1 \geq \dots \geq \lambda_p$$

$$k_j \text{ 很大, 超过 } \lambda_j \text{ 门槛} \rightarrow \text{多重共线性}$$

$$\hat{\beta}(k) \text{ 是 } \beta \text{ 的一种线性变换}$$

$$\text{本质这下对}$$

$$\|\hat{\beta}(k)\| < \|\beta\|$$

$$\min (y^T X \beta)^2 (y^T X \beta)$$

$$\text{s.t. } \beta^T \beta \leq s$$

主成分估计 有偏估计 $MSE(\hat{\beta}_R) < MSE(\hat{\beta})$

层次聚类、kmeans、GMM、DBSCAN 具体内容

外部聚类有效性：使用外部信息；内部：不使用

$$\text{纯度, } P = \sum P_i \left(\max_j \frac{P_{ij}}{P_j} \right) \quad \text{熵 } E = - \sum P_i \left(\sum_j \frac{P_{ij}}{P_i} \ln \frac{P_{ij}}{P_i} \right)$$

内部一致性 → 同一类内不同个体间紧密度的度量

偏差 \Rightarrow 低古音写密度小

区分半度 → 不同色调区别半度的度量
同半度 → 同色调区别半度的度量

R.Y.A. R.S.
RMSSTD.

(H指數) → 最大化, 可找到最優聚類數目 K
(类内差异小, 类间差异大)

GMN

具体看那几页

$$\alpha_t(i) = \pi(i) \cdot b_i(o_t) \quad \alpha_{t+1}(i) = \left(\sum_{j=1}^n \alpha_t(j) \cdot a_{j|i} \right) \cdot b_i(o_{t+1}) \quad P(o|s) = \sum_{i=1}^n \alpha_t(i)$$

$$\beta_t(i) = \left(\sum_{j=1}^n \beta_{t+1}(j) \cdot a_{ij} \cdot b_j(o_{t+1}) \right) \cdot P(o_{t+1}) = \sum_{j=1}^n \pi_j \cdot b_j(o_{t+1})$$

760